SOSYAL BİLİMLERDE ARAŞTIRMA YÖNTEMLERİ

Hafta 6 — Kitap Bölümü

Ders 6 · Nicel Veri Analizi ve Yorumlama

Veriyi Tanımaktan Etki Büyüklüğüne: Betimsel, Çıkarımsal ve Yorum

Ders 6 · Nicel Veri Analizi ve Yorumlama

Veriyi Tanımaktan Etki Büyüklüğüne: Betimsel, Çıkarımsal ve Yorum

Hafta 6 · Bu bölümün sorusu: “Anlamlı çıktı” ne demek, ne demek değil?

> — **Selin:** Hocam, sonuç çıktı! Kavram haritası kullanan grubun ortalaması yüksek ve p değeri ,019. Yani anlamlı.
>
> — **Danışman:** Güzel. Peki fark kaç puan?
>
> — **Selin:** Şey… ona bakmadım. SPSS “Sig. (2-tailed) ,019” yazınca sevindim ve doğrudan yazmaya oturdum.
>
> — **Danışman:** Deney grubu 27,5; kontrol grubu 24,1. Fark 3,4 puan. Testin tamamı 40 puan üzerinden. Şimdi soru şu: bu 3,4 puan, bir öğretmenin dersini değiştirmesini gerektirecek kadar büyük mü?
>
> — **Selin:** O ayrı bir soru değil mi? p zaten anlamlı çıktı.
>
> — **Danışman:** İşte bu cümle, tezlerde en sık düzelttiğim cümle. **p size farkın büyük olduğunu değil, sıfır olmadığını düşündürecek kadar veri topladığınızı söyler.** Büyüklüğü söyleyen başka bir sayı var; onu bu hafta öğreneceğiz.

Bu Bölümde

· 6.1 · Analizden önce: veriyi tanımak	· 6.4 · Test seçimi ve uygulama
· Veri girişi · Kayıp veri · Aykırı değer	· t-testi · ANOVA · Ki-kare · Korelasyon · Regresyon
· Ölçek düzeyleri ve hangi analizin hangi düzeyi gerektirdiği	· Varsayımlar · Test seçim akış şeması · SPSS'te adım adım
· 6.2 · Betimsel istatistik	· Varsayım ihlalinde karar tablosu · t-testi çıktısının sekiz sütunu
· Merkezî eğilim · Yayılım · Çarpıklık ve basıklık	· 6.5 · Yorumlama
· Ortalamanın yanıltıcı olduğu durumlar · Tabloyu doğru okumak	· ASA'nın altı ilkesi · Etki büyüklüğü · Kısmi eta kare tuzağı
· 6.3 · Çıkarımsal istatistiğin mantığı	· İstatistiksel ≠ pratik anlamlılık · APA 7'ye göre raporlama
· Örnekleme dağılımı · Standart hata · Güven aralığı	· Sonuç cümlesi nasıl yazılır: dört kötü / iyi çift
· Sıfır hipotezi · I. ve II. tip hata · İstatistiksel güç	· Uygulama Yaprağı 6 · Nicel analiz planı

Amaçlar

Bu bölümü çalıştığınızda şunları yapabileceksiniz:

- Bir veri dosyasını analiz öncesi temizlemenin adımlarını sırayla uygular.
- Kayıp veriyi ve aykırı değeri ayırt eder; her biri için uygun kararı gerekçelendirir.
- Dört ölçek düzeyini örnekleriyle tanımlar ve her düzeyin izin verdiği analizi belirtir.

- Bir dağılım için uygun merkezî eğilim ve yayılım ölçüsünü seçer ve seçimini savunur.
- Ortalamanın yanıltıcı olduğu durumları örnekle açıklar.
- Örnekleme dağılımı, standart hata ve güven aralığı arasındaki bağı kurar.
- Güven aralığını doğru cümleyle yorumlar; yanlış yorumu düzeltir.
- I. tip ve II. tip hatayı bir karar tablosunda konumlandırır ve gücü tanımlar.
- Bir araştırma sorusundan hareketle uygun istatistiksel testi akış şemasıyla seçer.
- Parametrik test varsayımlarını denetler ve karşılanmadığında ne yapacağını yazar.
- ASA'nın p-değeri açıklamasındaki altı ilkeyi sayar ve p'nin ne olmadığını açıklar.
- Bir bulguyu etki büyüklüğü ve güven aralığıyla birlikte APA 7'ye uygun raporlar.

6.1 · Analizden Önce: Veriyi Tanımak

Analiz, SPSS'in **Analyze** menüsüne tıkladığınız anda başlamaz. Orada başlarsa, çoğu zaman hatayla başlar. Analiz, veri dosyasını ilk kez açıp ona bakmakla başlar: kaç satır var, kaç sütun var, sütunlarda ne yazıyor, boş bırakılmış hücreler nerede. Bu bölümün ilk kuralı şudur: **hiçbir veriyi, ona bakmadan analiz etmeyin.** Field'ın bütün varsayım tartışmasının altında yatan basit fikir budur (Field, 2018).

Veri dosyasının dilbilgisi tek cümleyle özetlenir: **her satır bir birey, her sütun bir değişkendir** (Fraenkel ve Wallen, 2009, s. 188). Bu kural kulağa apaçık gelir ama en sık yapılan hata da buradan çıkar. *Kötü örnek:* Bir yüksek lisans öğrencisi ön test ve son test puanlarını ayrı iki dosyaya koyar ve bunları eşleştirmeden karşılaştırmaya çalışır. *İyi örnek:* Aynı öğrenci tek bir dosya kurar; sütunlar sırasıyla `id`, `grup`, `cinsiyet`, `ontest`, `sontest` olur ve her satır bir öğrenciye aittir. Eşleştirilmiş analiz ancak bu dosya yapısıyla mümkündür.

Veri girişinden hemen sonra gelen adım **kodlama defteridir**. Kodlama defteri, her sütunun adını, ne ölçtüğünü, hangi sayının hangi kategoriye karşılık geldiğini (1 = kız, 2 = erkek) ve kayıp veri için hangi kodun kullanıldığını (örneğin −1 ya da 99) yazan kısa bir belgedir. Varsayalım ki dosyanızda `oktur` adlı bir sütun var ve içinde 1'ler ile 2'ler duruyor. Kodlama defteri olmadan üç ay sonra bu sütuna baktığınızda 1'in devlet okulu mu özel okul mu olduğunu hatırlayamazsınız; hatırlıyor sanıp yanlış yorumlamak daha da kötüdür. Williams ve arkadaşları aynı gerekçeyle **fare tıklamaları yerine sözdizimi (syntax) dosyası** kullanmayı önerir: tıklama kayıt bırakmaz, sözdizimi bırakır (Williams ve ark., 2021). SPSS'te her işlemi çalıştırmadan önce **Paste** düğmesine basıp komutu biriktirmek, yeniden üretilebilirliğin en ucuz biçimidir; analizi altı ay sonra yinelemeniz gerektiğinde tek yapacağınız o dosyayı çalıştırmak olur.

> TANIM **Kayıp veri, aykırı değer, veri temizliği. Kayıp veri:** Toplanması planlanan ama elde edilemeyen değer. **Birim yanıtsızlığı** kişinin hiç katılmaması, **madde yanıtsızlığı** katılan kişinin bir soruyu boş bırakmasıdır. **Aykırı değer:** Dağılımın geri kalanından belirgin biçimde uzak duran gözlem; ya bir giriş hatasıdır ya gerçek bir uç gözlemdir. **Veri temizliği:** Analizden önce hataları bulup düzeltme, kayıp veriyi işaretleme ve her kararı belgeleme işidir.

Kayıp veri iki farklı hayvandır ve karıştırılmamalıdır. *Birim yanıtsızlığı*, bir kişinin ölçme aracına hiç katılmamasıdır; o satırın tamamı boştur. *Madde yanıtsızlığı*, katılan birinin belirli bir soruyu boş bırakmasıdır (Williams ve ark., 2021, s. 119). İkisi farklı kararlar gerektirir. Varsayalım ki 120 öğrenciye uyguladığınız ölçekte 6 öğrenci ölçeği hiç doldurmamış, 9 öğrenci ise 24 maddenin bir ya da ikisini boş bırakmıştır. İlk 6 satır analizden çıkar; kalan 9 satır için ise silmek yerine madde ortalamasıyla tamamlamak çoğu zaman daha az bilgi kaybettirir.

Kayıp veriyi görmezden gelmenin bedeli somuttur. Williams ve arkadaşlarının aktardığı boylamsal örnekte, 9.790 kişilik bir veri kümesinde her değişken için **liste bazında silme** uygulandığında geriye yalnızca 5.795 tam vaka kalır; yani örneklemin %41'i, her biri en az bir maddeyi boş bıraktığı için atılmıştır (Williams ve ark.,

2021). Bu yalnızca bir sayı kaybı değildir: geriye kalanlar, formu sonuna kadar dolduracak sabra ve güdüye sahip kişilerdir — yani örneklem sessizce **yanlı** hâle gelmiştir. Ders şudur: kayıp veri, bir temizlik ayrıntısı değil, **örneklemin yeniden tanımlanmasıdır.** Tezinizde kaç vakayla başladığınızı ve kaç vakayla analiz yaptığınızı yazmak zorundasınız; ayrıca kayıp verisi olanlarla olmayanların birkaç temel değişkende (cinsiyet, sınıf düzeyi, ön test puanı) benzer olup olmadığını denetlemek iyi bir uygulamadır.

Aykırı değerin iki türü vardır ve ikisi bambaşka şeylerdir. Birincisi **hatadır**: veri girişinde yapılmış bir yazım yanlışı. Field'ın 810 katılımcılık örneğinde histogramda tek bir uç değer görünür: 20. Oysa ölçek 0–4 aralığındadır; demek ki bu bir hatadır. Kutu grafiği aykırı vakanın satır numarasını verir (611); o satıra gidildiğinde 20.02 değerinin aslında **2.02**'nin yanlış yazımı olduğu anlaşılır (Field, 2018). Bu tür bir aykırı değer düzeltilir, silinmez.

İkincisi **gerçek bir uç gözlemdir**: veri doğru girilmiştir, o öğrenci gerçekten öyle bir puan almıştır. Bunu silmek veri uydurmaktır. Peki neden önemsiyoruz? Çünkü aykırı değer, kestirimden çok **kestirimin hatasını** bozar. Field'ın küçük örneği çarpıcıdır: 1, 3, 4, 3, 2 verisinde ortalama 2,6 ve kareler toplamı 5,2'dir. Yalnızca 4 yerine 10 yazıldığında ortalama 3,8'e çıkar ama kareler toplamı **50,8**'e fırlar ve bu hatanın 38,44'ü tek başına o değerden gelir (Field, 2018). Kareler toplamı bozulunca standart sapma, standart hata, güven aralığı ve test istatistiği de bozulur.

Bu yüzden aykırı değere karar verirken şu sırayı izleyin: (1) histogram ve kutu grafiğiyle bulun; (2) ham veriye dönüp **hata mı, gerçek mi** olduğunu belirleyin; (3) hataysa düzeltin; (4) gerçekse silmeyin, ama analizi hem onunla hem onsuz çalıştırıp sonucun değişip değişmediğini raporlayın; (5) her kararınızı yazın. Beşinci adım en çok atlanan adımdır ve en pahalıya mal olanıdır: jüri "bu vakayı neden çıkardınız?" diye sorduğunda verilecek tek meşru cevap, kuralı **veri toplanmadan önce** yazmış olmaktır. Field'ın uyarısı ayrıca önemlidir: **örneklem büyükse aykırı değerler normallikten daha acil bir sorundur** (Field, 2018). Nedeni basittir: örneklem büyüdükçe merkezî limit teoremi normallik sorununu kendiliğinden hafifletir, ama tek bir uç değerin kareler toplamı üzerindeki etkisi hafiflemez.

> ÖRNEK **Aynı hücre, iki farklı karar.** Varsayalım ki 5'li Likert ölçeğinde bir hücrede **44** yazıyor. Ölçeğin üst sınırı 5 olduğuna göre bu bir hatadır: ham forma bakılır, büyük olasılıkla **4** yazılacakken tuşa iki kez basılmıştır → **düzeltilir.** Başka bir hücrede, 40 puanlık tarihsel düşünme testinde bir öğrenci **9** almıştır; sınıf ortalaması 25'tir. Ham forma bakılır, öğrenci gerçekten 9 almıştır → **silinmez.** İkinci durumda yapılacak iş, analizi bu öğrenciyle ve onsuz iki kez çalıştırıp sonucun değişip değişmediğini yöntem bölümünde bir cümleyle bildirmektir.

> DİKKAT **Türkçe yazında sık görülen üç veri hatası. (1) "Kayıp veri yoktu" demek.** 120 kişiye uygulanan ölçekte hiç boş hücre olmaması olağandışıdır; genellikle boş satırlar sessizce silinmiştir. Kaç vakayla başladığınızı ve kaç vakayla bitirdiğinizi yazın. **(2) Ters maddeyi ters kodlamamak.** Field'ın örneğinde tek bir ters madde kodlanmadığında Cronbach alfa 0,821 yerine **0,605** çıkar ve o madde **negatif** madde-toplam korelasyonu verir (Field, 2018). **(3) Sınıflama düzeyinde ortalama almak.** "Branş değişkeninin ortalaması 2,3" cümlesi hiçbir şey söylemez.

Şimdi bu bölümün en çok işinize yarayacak parçasına geliyoruz: **ölçek düzeyleri.** Dördüncü haftada değişkenleri tanımlarken ölçme düzeylerini kurmuştuk; burada onların analiz sonuçlarını göreceksiniz. **Sınıflama (nominal)** düzeyinde sayılar yalnızca etikettir: 1 = kız, 2 = erkek. İkinin birden büyük olması hiçbir şey ifade etmez; bu düzeyde ortalama hesaplanamaz, yalnızca frekans ve yüzde verilir. *Örnek:* "Katılımcıların ortalama cinsiyeti 1,54'tür" cümlesi anlamsızdır.

Sıralama (ordinal) düzeyinde sıra vardır ama aralıklar eşit değildir. Bir öğrencinin sınıf içi başarı sırasının 1, 2, 3 olması, birinci ile ikinci arasındaki farkın ikinci ile üçüncü arasındakine eşit olduğunu göstermez. *Örnek:*

Bir bilgi yarışmasında birinci 92, ikinci 91, üçüncü 63 puan almışsa, sıra sayıları 1, 2 ve 3'tür; oysa birinci ile ikinci arasında yalnızca 1 puan, ikinci ile üçüncü arasında 28 puan vardır. Sıra bu uçurumu tümüyle gizler. Bu düzeyde medyan ve sıra temelli testler (Mann-Whitney U, Kruskal-Wallis, Spearman) kullanılır. Tek bir Likert maddesi de — "Sosyal bilgiler dersini severim: 1 = hiç katılmıyorum … 5 = tamamen katılıyorum" — bu düzeydedir: "katılmıyorum" ile "kararsızım" arasındaki psikolojik uzaklığın, "kararsızım" ile "katılıyorum" arasındakine eşit olduğunu kimse gösterememiştir.

Eşit aralıklı (interval) düzeyde aralıklar eşittir ama mutlak sıfır yoktur. Bir başarı testinden 0 almak, öğrencinin hiç bilgisi olmadığı anlamına gelmez; yalnızca o testteki hiçbir maddeyi doğru yapmadığı anlamına gelir. Bunun pratik sonucu şudur: 40 puanlık bir testte 30 alan öğrencinin, 15 alandan "iki kat başarılı" olduğunu **söyleyemezsiniz**; yalnızca 15 puan daha fazla aldığını söyleyebilirsiniz. **Oran (ratio)** düzeyinde ise mutlak sıfır vardır: "öğrencinin bir haftada okuduğu kitap sayısı" sıfır olabilir ve sıfır gerçekten "hiç" demektir. Burada oran kurmak meşrudur: haftada 4 kitap okuyan öğrenci, 2 kitap okuyanın gerçekten iki katı okumaktadır. Her iki düzeyde de ortalama, standart sapma ve parametrik testler kullanılabilir.

Tablo 6.1 · Dört ölçek düzeyi ve izin verdiği analiz

Düzey	Ne yapar	Eğitimden örnek	Merkez ölçüsü	Tipik analiz
Sınıflama	Yalnızca etiketler; sıra yok	Okul türü (devlet/özel), branş, cinsiyet	Mod	Frekans, yüzde, ki-kare
Sıralama	Sıra var; aralıklar eşit değil	Başarı sırası, tek bir Likert maddesi, tercih sırası	Medyan	Mann-Whitney U, Kruskal-Wallis, Spearman
Eşit aralıklı	Aralıklar eşit; mutlak sıfır yok	Başarı testi puanı, çok maddeli ölçek toplam puanı	Ortalama	t-testi, ANOVA, Pearson r, regresyon
Oran	Aralıklar eşit; mutlak sıfır var	Okunan kitap sayısı, ders çalışma süresi, devamsızlık günü	Ortalama	t-testi, ANOVA, Pearson r, regresyon

> ÖRNEK **Ölçek düzeyi, analizi nasıl belirler?** Aynı araştırmada dört değişken var. *Okul türü* (devlet/özel) → sınıflama → **yüzde, ki-kare.** *Sosyal bilgiler dersini sevme sırası* (1., 2., 3. sırada) → sıralama → **medyan, Mann-Whitney U.** *Tarihsel düşünme testi puanı* (0–40) → eşit aralıklı → **ortalama, t-testi.** *Bir haftada okunan kitap sayısı* (0, 1, 2…) → oran → **ortalama, korelasyon.** Dördü de aynı öğrencilerden toplanmıştır; ama dördü aynı testle analiz edilemez.

Ölçek düzeyi yalnızca hangi testi seçeceğinizi değil, hangi cümleyi kurabileceğinizi de belirler. *Kötü örnek:* "Öğrencilerin ortalama sosyal bilgiler dersi sevme düzeyi 3,84'tür" — tek bir Likert maddesi için bu cümle sıralama düzeyini aşar. *İyi örnek:* "Öğrencilerin %62'si maddeye 'katılıyorum' ya da 'tamamen katılıyorum' yanıtını vermiştir; ortanca yanıt 'katılıyorum'dur." Aynı veriden kurulan ikinci cümle, hem daha az iddialı hem daha bilgilendiricidir. Eğitim araştırmalarında en çok tartışılan nokta, Likert tipi ölçeklerin hangi düzeyde sayılacağıdır. Katı görüş bunları sıralama düzeyi sayar; yaygın uygulama ise **çok maddeli bir ölçekten elde edilen toplam puanı** eşit aralıklı kabul edip parametrik test uygulamaktır. Fraenkel ve Wallen bu konudaki dürüst çekinceyi koyar: araştırmacılar verilerinin gerçekten eşit aralıklı ölçek varsayımını haklı çıkarıp çıkarmadığını nadiren kesin olarak bilir (2009, s. 229). **Size önerimiz nettir:** tek maddeyi sıralama sayın, çok maddeli ölçeğin toplam puanını eşit aralıklı sayın, bu tercihi yöntem bölümünde bir cümleyle gerekçelendirin ve sonucu ihtiyatlı yorumlayın.

Tablo 6.2 · Kayıp veri ve aykırı değer: karar tablosu

Durum	Nasıl anlaşılır	Ne yapılır	Raporda ne yazılır
Birim yanıtsızlığı	Satırın tamamı boş; kişi ölçeği	Satır analizden çıkarılır	"120 formdan 6'sı boş döndüğü

Durum	Nasıl anlaşılır	Ne yapılır	Raporda ne yazılır
	hiç doldurmamış		için analiz 114 kişiyle yürütülmüştür.”
Madde yanıtsızlığı (seyrek)	24 maddenin 1–2'si boş	Ölçek ortalamasıyla tamamlanır ya da o analizden dışlanır	Kaç vakada kaç madde tamamlandığı yazılır
Madde yanıtsızlığı (yoğun)	Bir kişi maddelerin üçte birinden fazlasını boş bırakmış	Vaka analizden çıkarılır	Dışlama ölçütü sayıyla belirtilir
Aykırı değer — hata	Ölçeğin sınırlarını aşıyor (5'lik ölçekte 44)	Ham forma dönülür ve **düzeltilir**	Kaç hücrenin düzeltildiği bir cümleyle bildirilir
Aykırı değer — gerçek	Değer doğru girilmiş; katılımcı gerçekten öyle puan almış	**Silinmez;** analiz onunla ve onsuz iki kez çalıştırılır	Duyarlılık analizinin sonucu bildirilir

6.2 · Betimsel İstatistik: Veriyi Konuşturmak

Betimsel istatistiğin işi tek cümleyle söylenir: **çok sayıda puanı birkaç sayıyla özetlemek.** Örneklemden hesaplanan bu özet göstergelere *istatistik*, tüm evrenden hesaplananlara *parametre* denir (Fraenkel ve Wallen, 2009, s. 185). Eğitim araştırmalarının neredeyse tamamı örneklemle çalıştığı için elimizdekiler istatistiktir; parametre, kestirmeye çalıştığımız ama hiçbir zaman doğrudan göremediğimiz sayıdır.

Bir dağılımı üç soruyla tanırsınız: **Merkezi nerede? Ne kadar yayılmış? Biçimi nasıl?** Merkez sorusunun üç cevabı vardır. **Mod**, en sık görülen puandır; iki tepe varsa dağılım iki modludur ve bu genellikle iki farklı alt grubun karıştığının işaretidir. **Medyan (ortanca)**, puanların yarısının altında yarısının üstünde kaldığı orta noktadır. **Ortalama**, tüm puanların toplamının puan sayısına bölümüdür ve dağılımdaki bütün bilgiyi kullanan tek ölçüdür — ama tam bu yüzden **uç değerlerden aşırı etkilenir** (Fraenkel ve Wallen, 2009, s. 192–193).

> TANIM **Merkez, yayılım, biçim. Mod:** En sık görülen puan. **Medyan:** Ortadaki puan; %50 altta, %50 üstte. **Ortalama:** Toplam / n. **Ranj:** En yüksek − en düşük. **Çeyrekler arası açıklık:** Q3 − Q1. **Standart sapma:** Puanların ortalamadan ortalama uzaklığının bir ölçüsü; **varyansın karekökü**dür ve orijinal verinin biriminde ifade edilir (Field, 2018). **Çarpıklık:** Simetriden sapma. **Basıklık:** Kuyruklarda kümelenme.

Ortalamanın yanıltıcı olduğu klasik örnek maaşlardır. On kişilik bir işletmede ortalama maaş 75.000, medyan maaş 27.000'dir; aradaki farkı patronun 475.000'lik maaşı yaratır (Fraenkel ve Wallen, 2009, s. 193). Stockemer'in beş sayılık örneği aynı dersi daha da hızlı verir: 60, 60, 90, 70, 200 dizisinin ortalaması 96'dır; 200 çıkarıldığında 70'e düşer. Medyan ise 70'tir ve 200 çıkarıldığında yalnızca 65'e iner (Stockemer, 2019, s. 79–80). **Kural:** dağılım çarpıksa ya da uç değer varsa, ortalamanın yanına medyanı da yazın.

Yayılım sorusunun cevapları da üç tanedir. **Ranj**, en yüksek ile en düşük puan arasındaki uzaklıktır; hızlı ama kabadır, çünkü yalnızca iki puanı kullanır. Varsayalım ki bir sınıfın puanları 12 ile 38 arasında; ranj 26'dır ve bu sayı, aradaki 28 öğrencinin nerede toplandığı hakkında hiçbir şey söylemez. **Çeyrekler arası açıklık (ÇAA)**, üçüncü çeyrek ile birinci çeyrek arasındaki farktır ve ortadaki %50'nin ne kadar yayıldığını söyler; aynı sınıfta Q1 = 22 ve Q3 = 30 ise ÇAA = 8'dir ve öğrencilerin yarısının sekiz puanlık dar bir bantta toplandığını öğrenirsiniz. **Standart sapma**, ortalama gibi her puanı kullanır ve yayılımın en kullanışlı göstergesidir (Fraenkel ve Wallen, 2009, s. 194–195). Williams ve arkadaşlarının somut kavrayış örneği akılda kalır: bir mağazada ortalama palto 50 avro, standart sapma 10 avro ise paltoların çoğu 40–60 avro arasındadır; ortalama yine 50 ama standart sapma 100 ise aralık çok daha geniştir (Williams ve ark., 2021, s. 29).

Aynı ayrım standart sapmanın kendisi için de geçerlidir. Standart sapma, varyansın kareköküdür ve **orijinal verinin biriminde** ifade edilir (Field, 2018); bu yüzden yorumlanabilir. Varyans ise puan biriminin karesindedir — "5,3 puan" anlaşılır, "28,09 puan-kare" anlaşılmaz. Tez tablolarında varyans değil standart sapma raporlanmasının nedeni budur. Ortalamayı yayılım vermeden raporlamak, tabloyu yanlış okumanın en yaygın biçimidir. Fraenkel ve Wallen'ın örneği açıktır: bir ligdeki oyuncuların ortalama yıllık kazancını söylemek, bazılarının çok daha az, bazılarının ise kat kat fazla kazandığını gizler (2009, s. 194). *Kötü örnek:* "Deney grubunun son test ortalaması 27,5'tir." *İyi örnek:* "Deney grubunun son test ortalaması 27,5'tir (SS = 5,3; n = 30)." İkinci cümle üç sayı daha verir ve okur artık dağılımı zihninde canlandırabilir.

> ÖRNEK **Ortalamanın yalan söylediği üç durum. (1) Uç değer varsa:** 60, 60, 90, 70, 200 → ortalama 96, medyan 70 (Stockemer, 2019, s. 79–80). **(2) Dağılım iki tepeliyse:** Ortalama, hiçbir öğrencinin bulunmadığı bir "orta" noktayı gösterir. **(3) Ölçek düzeyi uygun değilse:** "Öğretmenlerin branş ortalaması 2,3" cümlesi bir bilgi taşımaz. Üçünde de çözüm aynıdır: **grafiğe bakın ve medyanı ekleyin.**

İki dağılımın ortalaması ve medyanı aynı olup yayılımları taban tabana zıt olabilir. Fraenkel ve Wallen'ın örneğinde A dizisi 19, 20, 25, 32, 39; B dizisi 2, 3, 25, 30, 75'tir. Her ikisinde de ortalama 27, medyan 25'tir (2009, s. 194). Sınıf gerçekliğine çevirelim: iki şubenin ortalaması aynı çıkabilir ama birinde öğrenciler ortalama etrafında toplanmış, diğerinde sınıf ikiye ayrılmış olabilir. Öğretmen için bu iki durum bambaşkadır; yalnızca ortalamaya bakan bir rapor bu farkı görünmez kılar.

> ÖRNEK **Aynı ortalama, iki bambaşka sınıf.** Varsayalım ki iki şubede 40 puanlık aynı test uygulandı. **7-A:** 22, 24, 25, 25, 26, 27, 28, 29 → ortalama 25,75; SS ≈ 2,25. **7-B:** 8, 12, 18, 24, 27, 33, 38, 46 (46 puan bonus maddeyle) → ortalama 25,75; SS ≈ 12,4. Ortalamalar aynı. Ama 7-A'da sınıf birlikte ilerliyor; 7-B'de sınıf ikiye ayrılmış. **Yalnızca ortalamayı raporlayan bir tez, öğretmenin en çok ihtiyaç duyduğu bilgiyi silmiş olur.**

Tablo 6.3 · Hangi merkezî eğilim ve yayılım ölçüsü?

Dağılımın durumu	Merkez ölçüsü	Yayılım ölçüsü	Gerekçe
Simetrik, uç değer yok	Ortalama	Standart sapma	Ortalama tüm bilgiyi kullanır; en verimli ölçüdür
Çarpık ya da uç değerli	Medyan (ortalamayla birlikte)	Çeyrekler arası açıklık	Ortalama uç değerlerden aşırı etkilenir
İki tepeli (bimodal)	Mod (ve alt grup ayrıştırması)	Ranj + grup içi SS	Tek bir merkez sayısı hiçbir öğrenciyi temsil etmez
Sıralama düzeyi	Medyan	Çeyrekler arası açıklık	Aralıklar eşit olmadığı için ortalama anlamsızdır
Sınıflama düzeyi	Mod	Kategori yüzdeleri	Sayılar etiket olduğu için ortalama hesaplanamaz

Biçim sorusunun cevabı **çarpıklık ve basıklıktır**. Çarpıklık, dağılımın simetri ölçüsüdür; simetrik dağılımda 0'dır. Puanlar alt uçta toplanmış ve kuyruk yüksek değerlere uzanıyorsa çarpıklık pozitiftir; tersi durumda negatiftir (Field, 2018). Sınıf gerçekliğine çevirelim: **çok zor bir sınav pozitif çarpık** bir dağılım verir — puanlar alt uçta toplanır, birkaç öğrenci yukarıya doğru uzanır. **Çok kolay bir sınav negatif çarpıktır** — puanlar tavana yapışır, kuyruk aşağıya uzanır. Kısacası kuyruk hangi yöne uzanıyorsa çarpıklığın işareti odur.

Basıklık, puanların dağılımın kuyruklarında ne ölçüde kümelendiğini ölçer. SPSS bu değeri, "basıklık yok" durumu 0 olacak biçimde raporlar; pozitif basıklık kuyruklarda beklenenden çok puan ve sivri bir tepe

demektir (Field, 2018). Türkçe yazında yaygın uygulama, çarpıklık ve basıklık değerlerinin yaklaşık **±1 aralığında** kalmasını normallik için yeterli saymaktır. Bu bir pratik kuraldır, bir yasa değil; **tek başına da kullanılmaz** — mutlaka histogramla birlikte okunur.

Grafik, sayıdan önce gelir. Fraenkel ve Wallen'ın yirmi önerisinin ilk maddesi tam olarak budur: **ilk adım olarak her grubun frekans poligonunu hazırlayın** ve hangi merkezî eğilim ölçüsünün uygun olduğuna bu grafiklere bakarak karar verin (2009, s. 243). Eşit aralıklı ve oranlı veri için histogram, sınıflama verisi için çubuk grafik kullanılır; ikisi arasındaki fark çubukların birbirine değip değmemesidir (2009, s. 189–191). Kutu grafiği ise beş sayıyı — en düşük puan, birinci çeyrek, medyan, üçüncü çeyrek, en yüksek puan — tek bakışta verir. Bu grafiklerin her biri farklı bir soruyu yanıtlar: histogram "dağılımın biçimi nasıl?", kutu grafiği "aykırı değer var mı ve ortadaki yarı nerede?", frekans poligonu ise "iki grubun dağılımları nerede ayrışıyor?" sorusunu. Sınıf gerçekliğinde en çok işe yarayanı sonuncusudur: iki grubun poligonu üst üste çizildiğinde, farkın bütün öğrencilerden mi yoksa yalnızca alt uçtaki birkaç öğrenciden mi geldiğini gözle görürsünüz.

Betimsel istatistiğin son iki aracı, gruplar arası karşılaştırmayı mümkün kılar. **z puanı**, ham puanın ortalamadan kaç standart sapma uzakta olduğunu söyler: z = (ham puan − ortalama) / standart sapma. Fraenkel ve Wallen'ın örneği sınıfta anlatılmaya değer: bir öğrenci biyolojiden 60, kimyadan 80 alır. Yüzeysel bakışta kimyada daha iyidir. Ama biyoloji ortalaması 50 ve standart sapması 5 ise z = +2; kimya ortalaması 90 ve standart sapması 10 ise z = −1. Öğrenci **aslında biyolojide daha başarılıdır** (2009, s. 198–199). Bu hesabın arkasındaki kural, normal dağılımda geçerli olan **68-95-99,7 kuralıdır**: puanların %68'i ortalamadan ±1 standart sapma, %95'i ±2, %99,7'si ±3 standart sapma içinde kalır (Fraenkel ve Wallen, 2009, s. 196–197). z = +2 olan öğrenci, bu kurala göre sınıfın üst %2'sindedir; z = −1 olan öğrenci ise yaklaşık alt %16'sında. Aynı öğrencinin iki dersteki konumu arasındaki uçurum ancak bu ortak ölçekle görülür.

İkinci araç **korelasyon katsayısıdır**. Pearson r, iki sürekli değişken arasındaki doğrusal ilişkinin gücünü −1 ile +1 arasında bir sayıyla verir. Ama katsayıya saçılım grafiğine bakmadan güvenmek tehlikelidir. Fraenkel ve Wallen, hepsi de yaklaşık r = ,50 veren beş farklı saçılım grafiği gösterir: birinde katsayı ilişkiyi tam yansıtır; birinde ilişki eğriseldir ve katsayı onu **eksik gösterir**; birinde iki ayrı alt grup vardır; birinde katsayı birkaç sıra dışı vaka yüzünden **şişmiştir** (2009, s. 247). Stockemer'in gösteriminde tek bir aykırı değer eklenmesi korelasyonu 0,2 puan düşürür (2019, s. 143).

> UYGULAMA **Betimsel tabloyu okuma sırası.** Bir makalede betimsel tabloya rastladığınızda şu sırayı izleyin: **(1) n'e bakın** — gruplar dengeli mi? **(2) Standart sapmalara bakın** — biri ötekinin iki katından büyük mü? **(3) Ortalama ile medyanı karşılaştırın** — ikisi verilmişse aralarındaki büyük fark çarpıklık işaretidir. **(4) En düşük ve en yüksek puana bakın** — ölçeğin sınırlarını aşan bir değer var mı? **(5) Ancak bundan sonra** test sonucuna geçin.

Bu bölümün pratik çıkarımı üç maddedir. **Bir:** önce çizin, sonra hesaplayın. **İki:** merkezî eğilimi asla yayılım olmadan raporlamayın. **Üç:** çarpık dağılımda medyanı ekleyin. Bu üç madde, tez jürilerinin bulgular bölümünde ilk baktığı üç şeydir; üçünü de yerine getiren bir tablo, okurun sizin gördüğünüzü görmesini sağlar. Büyüköztürk'ün Türkçe yazında yerleşmiş raporlama biçimi de aynı mantığı izler: betimsel tabloda her grup için n, ortalama ve standart sapma birlikte verilir; ardından test istatistiği, serbestlik derecesi ve p-değeri gelir (Büyüköztürk, 2025). Dördüncü haftada kurduğunuz değişken listesini şimdi bu tabloya çevirmeye hazırsınız.

6.3 · Çıkarımsal İstatistiğin Mantığı

Elinizde 60 öğrenci var; öğrenmek istediğiniz şey ise 60 öğrenci değil, onların temsil ettiği daha büyük bir kitle. **Çıkarımsal istatistik, örneklemden elde edilen bulguya dayanarak evren hakkında çıkarım yapmayı sağlayan işlemler bütünüdür** (Fraenkel ve Wallen, 2009, s. 216). Bu bölümün tamamı tek bir soruya cevap arar: elimdeki bu farkı, örneklem değişse de görür müydüm?

Cevap **örnekleme hatası** kavramıyla başlar. Bir örneklem ile evreni arasındaki fark kaçınılmazdır; hiçbir örnekleme yöntemi — seçkisiz örnekleme dâhil — tümüyle temsilî bir örneklem garanti etmez (Fraenkel ve Wallen, 2009, s. 217). Varsayalım ki aynı okuldan 30 kişilik örneklemler çekip her seferinde ortalama hesaplıyorsunuz: 24,1; 25,3; 23,8; 24,9… Hiçbiri diğerine eşit değil, ama hepsi birbirine yakın ve hepsi aynı okulun gerçek ortalamasının etrafında salınıyor. Bu ortalamaların oluşturduğu dağılıma **örnekleme dağılımı** denir; çıkarımsal istatistiğin tamamı bu dağılımın nasıl davrandığını bilmemize dayanır.

Örnekleme dağılımı gerçek bir nesne değildir. Field onu **tek boynuzlu ata** benzetir: neye benzediğini hayal edebiliriz ama gerçeğini asla göremeyiz (Field, 2018). Buna karşın davranışını biliriz: **merkezî limit teoremi**, örneklem büyüklüğü arttıkça (genellikle 30'un üstü) evrenin biçimi ne olursa olsun örnekleme dağılımının normale yaklaştığını söyler. Field'ın gösteriminde aşırı çarpık bir evrenden çekilen örneklemlerde n = 5 için dağılım hâlâ çarpıktır, n = 30'da çarpıklık kaybolur, n = 100'de tümüyle normaldir (Field, 2018).

Örnekleme dağılımının standart sapmasına **ortalamanın standart hatası** denir. Yorumu basittir: standart hata büyükse, örneklem ortalamaları birbirinden çok farklıdır ve elimizdeki ortalama evren ortalamasını temsil etmiyor olabilir (Field, 2018). Standart hata, standart sapmanın örneklem büyüklüğünün kareköküne bölünmesiyle yaklaşık hesaplanır. Buradan çıkan pratik sonuç, tez öğrencisinin en çok işine yarayan sonuçtur: **n arttıkça standart hata küçülür; kestirim keskinleşir.** Ama karekök yüzünden kazanç doğrusal değildir. Varsayalım ki standart sapma 5,4. n = 30 iken standart hata yaklaşık 0,99'dur; n = 120'ye çıkarsanız — yani dört kat veri toplarsanız — standart hata yalnızca yarıya, 0,49'a iner. **Kestirimi iki kat keskinleştirmek için dört kat veri gerekir.** Bu, örneklem büyüklüğü kararını verirken akılda tutulacak en gerçekçi kuraldır.

> TANIM **Beş temel kavram. Örnekleme hatası:** Örneklem ile evren arasındaki kaçınılmaz fark. **Örnekleme dağılımı:** Aynı evrenden çekilen çok sayıda örneklemin ortalamalarının dağılımı. **Standart hata:** Bu dağılımın standart sapması. **Güven aralığı:** Evren parametresinin makul biçimde içinde bulunabileceği aralık. **İstatistiksel güç (1 − β):** Var olan bir etkiyi bulabilme olasılığı; hedef ,80 (Cohen, 1988).

Güven aralığı, bu keskinliği okura gösteren araçtır: örneklem istatistiğinin altına ve üstüne uzanan, evren parametresinin belirli bir olasılıkla içinde yer aldığı söylenebilecek bölge. %95 güven aralığı yaklaşık olarak ortalama ± 1,96 × standart hatadır; %99 için çarpan 2,58'dir (Fraenkel ve Wallen, 2009, s. 220–221). Stockemer'in elle hesap örneğinde 10 öğrencinin haftalık ders çalışma saatleri (7, 8, 12, 3, 11, 14, 11, 10, 9, 8) ortalama 9,3 verir; standart sapma 3,06'dır ve %95 güven aralığı kabaca **3,5 – 15,1 saattir** (2019, s. 95). Aralık geniştir, çünkü gözlem azdır.

Güven aralığının yorumu, bu bölümdeki en sık yapılan hatadır ve düzeltilmesi gerekir. *Kötü örnek:* “Bu %95 güven aralığının evren ortalamasını içerme olasılığı %95'tir.” Bu cümle **yanlıştır.** Evren ortalaması sabit bir değerdir; ya aralığın içindedir ya değildir (Fraenkel ve Wallen, 2009, s. 221; Field, 2018). *İyi örnek:* “Çalışmayı aynı biçimde yüz kez yineleyip her seferinde %95 güven aralığı hesaplasaydım, bu aralıkların yaklaşık 95'i evren ortalamasını içerirdi.” %95, tek bir aralığa değil, **uzun dönemli bir yönteme** ilişkin bir orandır.

> ÖRNEK **Güven aralığı: yanlış cümle / doğru cümle.** Varsayalım ki deney ile kontrol grubu arasındaki fark 3,4 puan ve %95 güven aralığı [0,61 – 6,19]. *Kötü örnek:* “Gerçek farkın 0,61 ile 6,19 arasında olma olasılığı %95'tir.” *İyi örnek:* “Fark 3,4 puandır; %95 güven aralığı [0,61 – 6,19]. Aralık sıfırı içermediği için fark ,05 düzeyinde anlamlıdır; ancak aralığın genişliği, gerçek farkın 1 puan kadar küçük de 6 puan kadar büyük de olabileceğini gösterir.” İkinci cümle hem sonucu hem belirsizliği verir.

Şimdi hipotez testine geçelim. **Araştırma hipotezi**, evrende var olduğunu düşündüğünüz ilişkiyi belirtir. **Sıfır hipotezi**, evrende ilişki olmadığını söyler: iki evren ortalaması arasındaki fark sıfırdır (Fraenkel ve Wallen,

2009, s. 224). Sıfır hipotezi bir inanç değil, bir **karşılaştırma çizgisidir**: alternatif hipotezin ne kadar akla yatkın olduğunu ancak ona göre değerlendirebiliriz (Field, 2018).

Fraenkel ve Wallen hipotez testinin mantığını altı adımda özetler: (1) araştırma hipotezini kur; (2) sıfır hipotezini kur; (3) örneklem istatistiklerini hesapla; (4) sıfır hipotezi doğruysa bu sonucu elde etme olasılığını belirle; (5) olasılık küçükse sıfır hipotezini reddet ve araştırma hipotezini destekle; (6) olasılık büyükse sıfır hipotezini reddetme — bu, araştırma hipotezini **doğrulayamadığın** anlamına gelir (2009, s. 224). Altıncı adımdaki dile dikkat edin: "hipotez doğrulanmıştır" değil, "reddedilememiştir".

Anlamlılık düzeyi (alfa), bir sonucun örnekleme hatası sonucu ortaya çıkma olasılığının kabul edilen üst sınırıdır; eğitim araştırmalarında ,05 ve ,01 yaygındır (Fraenkel ve Wallen, 2009, s. 224). ,05'in kaynağı ise bir doğa yasası değil, bir kolaylıktır. Fisher'ın çay tadan hanım deneyinde altı fincanla 20 olası sıralama vardır ve doğru sırayı şansla bulma olasılığı 20'de 1'dir (Field, 2018). Fisher hiçbir zaman ,05'in sihirli bir sayı olduğunu söylemedi; bilgisayar öncesi dönemde yalnızca birkaç olasılık değeri için kritik değer tablosu basıldığı için bu eşik yerleşti (Field, 2018). **Alfa veri toplanmadan önce seçilir; sonradan seçmek hiledir.**

Karar verirken iki tür hata yapabilirsiniz. **I. tip hata**, doğru olan bir sıfır hipotezini reddetmektir: ortada etki yokken var demek. **II. tip hata**, yanlış olan bir sıfır hipotezini reddetmemektir: gerçekte var olan etkiyi kaçırmak (Fraenkel ve Wallen, 2009, s. 228; Field, 2018). Fraenkel ve Wallen'ın hekim örneği bunu akılda tutmayı kolaylaştırır: belirtilere bakıp gereksiz yere tedaviye başlamak I. tip hatadır; belirtileri yanlış alarm sayıp gerçekten hasta olan çocuğu tedavisiz bırakmak II. tip hatadır (2009, s. 229).

ŞEKİL **Şekil 6.1 · I. ve II. tip hata.** Dört gözlü bir tablo düşünün. Satırlar: kararınız (H_0'ı reddettim / reddetmedim). Sütunlar: gerçekte durum (H_0 doğru / H_0 yanlış). Sol üst göz **I. tip hata** (α), sağ alt göz **II. tip hata** (β), sağ üst göz **doğru karar = güç** (1 − β), sol alt göz doğru karardır. Alfa küçüldükçe sol üst göz daralır ama sağ alt göz genişler. Tablo 6.4 bu dört gözü ayrıntılandırır.

Tablo 6.4 · Karar tablosu: I. ve II. tip hata

Kararınız	Gerçekte H_0 doğru (etki yok)	Gerçekte H_0 yanlış (etki var)
H_0'ı reddettim ("anlamlı")	**I. tip hata** (α). Olmayan etkiyi bulmak. Geleneksel oran ,05. Örnek: Yöntemin işe yaramadığı hâlde "işe yarıyor" demek.	**Doğru karar — güç (1 − β).** Var olan etkiyi bulmak. Hedef değer ,80.
H_0'ı reddetmedim ("anlamsız")	**Doğru karar.** Olmayan etkiyi bulmamak.	**II. tip hata** (β). Var olan etkiyi kaçırmak. Kabul edilebilir üst sınır ,20 (Cohen, 1988). Örnek: Yöntem işe yaradığı hâlde küçük örneklem yüzünden fark bulunamaması.
Nasıl azaltılır?	Alfayı küçültmek, çoklu karşılaştırmayı düzeltmek, hipotez sayısını önceden sabitlemek	Örneklemi büyütmek, güvenilir ölçme aracı kullanmak, dış değişkenleri denetlemek, işlemin gücünü artırmak

İki hata birbiriyle takas içindedir. Alfayı küçültürseniz — yani I. tip hataya karşı katılaşırsanız — gerçekten var olan bir etkiyi kaçırma olasılığınız artar (Field, 2018). İşte bu ikinci olasılığın tümleyeni **istatistiksel güçtür**: testin, evrende var olan bir etkiyi bulabilme olasılığı. Cohen'in önerdiği kabul edilebilir en yüksek II. tip hata olasılığı ,20 olduğuna göre hedeflenen güç **,80**'dir (Cohen, 1988; 1992; Field, 2018). Fraenkel ve Wallen'ın teleskop benzetmesi işe yarar: düşük güçlü teleskopla Mars'ın küre olduğu görülür, ama uyduları görülmez (2009, s. 235).

ÖRNEK **"Anlamlı değil": kötü cümle / iyi cümle.** Anlamsız bir sonuç, **etkinin sıfır olduğunu söylemez.** Yalnızca etkinin, bu örneklem büyüklüğüyle bulunabilecek kadar büyük olmadığını söyler (Field, 2018).

> Bu yüzden şu iki cümleyi tezinize yazmayın: “Gruplar arasında fark yoktur.” “Değişkenler arasında ilişki yoktur.” Yerine şunu yazın: “Bu örneklemle, gruplar arasında istatistiksel olarak anlamlı bir fark bulunamamıştır (t(58) = 0,94; p = ,351; d = 0,24).” Etki büyüklüğünü vermek, okurun kaçırılmış bir etki olup olmadığını değerlendirmesini sağlar.

Gücü üç şey belirler: etkinin büyüklüğü, seçilen alfa düzeyi ve örneklem büyüklüğü (Field, 2018). Üçünün de sezgisel bir karşılığı vardır: etki büyükse onu bulmak kolaydır; alfayı küçültürseniz kendi elinizi bağlamış olursunuz; örneklem büyükse gürültü azalır ve sinyal görünür hâle gelir. Bunların üçünü bilirseniz dördüncüsünü hesaplayabilirsiniz; bu işleme **güç analizi** denir ve **veri toplamadan önce** yapılması gerekir. Fraenkel ve Wallen'ın hazır sayıları planlama yaparken çok işe yarar: ,05 düzeyinde ve seçkisiz örnekleme varsayımıyla, r = ,20'lik bir korelasyonun anlamlı çıkması için 100, r = ,30 için 49, r = ,50 için 16 kişi gerekir. İki grup ortalaması karşılaştırılıyorsa (standart sapma 15 varsayımıyla) 5 puanlık bir fark için grup başına 71, 10 puanlık fark için 18 kişi yeterlidir (2009, s. 230).

> ÖRNEK **Güç analizi: kaç kişi gerekir?** Varsayalım ki iki grubu 40 puanlık bir testle karşılaştıracaksınız ve alanyazına bakarak yaklaşık 5 puanlık bir fark bekliyorsunuz. Fraenkel ve Wallen'ın ,05 düzeyi için verdiği çizelgeye göre (standart sapma 15 varsayımıyla) **her grupta 71 kişi** gerekir; 10 puanlık bir fark için 18 kişi yeter (2009, s. 230). Korelasyon için: r = ,20'lik bir ilişkinin anlamlı çıkması için **100**, r = ,30 için 49, r = ,50 için 16 kişi gerekir. **Dersiniz:** “kaç kişiyle çalışayım?” sorusunun cevabı sezgide değil, beklediğiniz etkinin büyüklüğündedir — ve bu hesap **veri toplamadan önce** yapılır.

Güç analizinin çıktısı bir sayıdır ama kararı sizin vermeniz gerekir. Varsayalım ki hesap “grup başına 71 kişi” diyor ama okulunuzda ancak 2 şube, yani 56 öğrenci var. İki seçeneğiniz vardır: ya ikinci bir okul ekleyip örneklemi büyütürsünüz, ya da çalışmayı 56 kişiyle yapıp **düşük güçle çalıştığınızı sınırlılıklar bölümünde açıkça yazarsınız.** Yapmamanız gereken şey, hesabı hiç yapmayıp anlamsız çıkan sonucu “fark yoktur” diye raporlamaktır. Son bir tuzak: **çoklu karşılaştırma.** Tek bir testte I. tip hata yapmama olasılığı ,95'tir. Üç bağımsız test yaparsanız en az bir I. tip hata yapma olasılığı %14,3'e, on test yaparsanız **%40'a** çıkar (Field, 2018). Buna aileye göre hata oranı denir. En yaygın çözüm **Bonferroni düzeltmesidir**: alfa, karşılaştırma sayısına bölünür (on test için ölçüt ,005 olur). Bedeli de vardır: güç kaybı. Pratik önerimiz şudur — sınayacağınız hipotez sayısını önceden belirleyin ve yazın; on beş değişkeni birbiriyle korelasyona sokup anlamlı çıkanları toplamayın.

6.4 · Test Seçimi ve Uygulama

Test seçimi, sanıldığı gibi bir istatistik sorusu değildir. **Bir tasarım sorusudur** ve cevabı üç bilgide saklıdır: (1) sorunuz karşılaştırma mı, ilişki mi arıyor; (2) değişkenlerinizin ölçek düzeyi nedir; (3) kaç grup ya da kaç ölçüm var ve bunlar bağımsız mı, ilişkili mi? Fraenkel ve Wallen'ın çerçevesi tam da bu sadelikte kurulur: eğitim araştırmasının çoğu ya **iki veya daha çok grubu karşılaştırır** ya da **tek bir grup içinde değişkenleri ilişkilendirir**; veri de ya nicel ya kategoriktir. Dört olası birleşim, bütün karar tablosunun temelidir (2009, s. 242).

Bu üç bilgiyi elde ettikten sonra akış şeması kendiliğinden işler. **Karşılaştırma yolunda:** Bağımlı değişken sürekli ve iki bağımsız grup varsa → **bağımsız örneklemler t-testi.** Aynı kişilerin iki ölçümü karşılaştırılıyorsa (ön test – son test) → **ilişkili örneklemler t-testi.** Üç ya da daha çok bağımsız grup varsa → **tek yönlü ANOVA** ve ardından post hoc test. İki bağımsız değişkenin ortak etkisi inceleniyorsa → **faktöriyel (iki yönlü) ANOVA.** Gruplar arasında başlangıç farkı varsa ve bu fark düzeltilecekse → **ANCOVA.**

İlişki yolunda: İki sürekli değişken arasındaki ilişki soruluyorsa → **saçılım grafiği ve Pearson r.** İki kategorik değişken arasındaki ilişki soruluyorsa → **çapraz tablo ve ki-kare.** Bir değişkeni bir ya da daha çok

değişkenden kestirmek istiyorsanız → **doğrusal regresyon** (tek yordayıcıyla basit, birden çok yordayıcıyla çoklu). Veri sıralı düzeydeyse ya da parametrik varsayımlar karşılanmıyorsa → **Spearman sıra korelasyonu.**

ŞEKİL **Şekil 6.2 · Test seçim akış şeması. Soru 1: Ne arıyorsunuz?** *Grup karşılaştırması* → Soru 2'ye. *İlişki/kestirim* → Soru 4'e. — **Soru 2: Bağımlı değişkenin düzeyi?** *Sürekli* → Soru 3'e. *Kategorik* → **ki-kare.** — **Soru 3: Kaç grup ve bağımsız mı?** *2 bağımsız* → **bağımsız t-testi.** *2 ilişkili* → **ilişkili t-testi.** *3+ bağımsız* → **tek yönlü ANOVA + post hoc.** *2+ bağımsız değişken* → **faktöriyel ANOVA.** *Başlangıç farkı düzeltilecek* → **ANCOVA.** — **Soru 4: Değişkenlerin düzeyi?** *İki sürekli* → **Pearson r.** *Sıralı ya da varsayım yok* → **Spearman.** *İki kategorik* → **ki-kare + Cramér V.** *Kestirim isteniyor* → **regresyon.** — **Her yolun sonunda tek bir kutu daha var:** varsayımları denetle; karşılanmıyorsa sağlam ya da parametrik olmayan karşılığa geç.

Tablo 6.5 · Hangi soru → hangi test?

Araştırma sorusu	Bağımsız değişken	Bağımlı değişken	Test	Etki büyüklüğü
İki bağımsız grubun ortalaması farklı mı?	Kategorik, 2 grup	Sürekli	Bağımsız örneklemler t-testi	Cohen d
Aynı grubun ön–son testi farklı mı?	Kategorik, 2 ilişkili ölçüm	Sürekli	İlişkili örneklemler t-testi	Cohen d
Üç ve daha çok grubun ortalaması farklı mı?	Kategorik, ≥3 grup	Sürekli	Tek yönlü ANOVA + post hoc	Eta kare
İki bağımsız değişkenin ortak etkisi var mı?	Kategorik, ≥2 değişken	Sürekli	Faktöriyel (iki yönlü) ANOVA	Kısmi eta kare
Başlangıç farkı düzeltilerek karşılaştırma	Kategorik + kovaryant	Sürekli	ANCOVA	Kısmi eta kare
İki kategorik değişken ilişkili mi?	Kategorik	Kategorik	Ki-kare (χ^2)	Cramér V, odds oranı
İki sürekli değişken ilişkili mi?	Sürekli	Sürekli	Saçılım grafiği + Pearson r	r'nin kendisi
Sıralı veri ya da varsayım karşılanmıyor	Sürekli/sıralı	Sıralı	Spearman r_s	r_s'nin kendisi
Bir değişkeni kestirmek	Sürekli/kukla	Sürekli	Basit ya da çoklu regresyon	R^2, düzeltilmiş R^2
Parametrik varsayım yok — 2 bağımsız grup	Kategorik, 2	Sıralı	Mann-Whitney U	$r = z/\sqrt{N}$
Parametrik varsayım yok — ≥3 bağımsız grup	Kategorik, ≥3	Sıralı	Kruskal-Wallis	Epsilon kare
Parametrik varsayım yok — ilişkili ölçümler	Kategorik, ilişkili	Sıralı	İşaret testi / Friedman	Kendall W

Testleri tanıyalım. **Bağımsız örneklemler t-testi**, iki farklı grubun ortalamalarını karşılaştırır. Mantığı bir sinyal/gürültü oranıdır: payda ortalamalar farkı, paydada bu farkın standart hatası vardır (Stockemer, 2019, s. 102–104). Bir farkı görebilmek için iki koşul gerekir: ortalamalar hatırı sayılır ölçüde farklı olmalı **ve** iki dağılımın yayılımı görece düşük olmalıdır. Aynı grubun ön ve son test ortalamaları karşılaştırılıyorsa **ilişkili örneklemler t-testi** kullanılır; iki testi karıştırmak, tezlerde en sık rastlanan yanlış test seçimidir.

Tek yönlü ANOVA, ikiden çok grubun ortalamaları arasında fark olup olmadığını sınar ve bir F değeri üretir. Mantığı toplam varyansı ikiye ayırmaktır: gruplar arası varyans ve grup içi varyans. Gruplar arası değişkenlik grup içi değişkenlikten hatırı sayılır ölçüde büyükse gruplar farklıdır (Stockemer, 2019, s. 112). **Kritik nokta:** F testi hangi grupların birbirinden farklı olduğunu **söylemez**; bunun için post hoc analiz gerekir (Fraenkel ve Wallen, 2009, s. 232). F anlamlı çıktı diye "üç yöntem birbirinden farklıdır" yazmak yanlıştır.

Ki-kare, kategorik veride beklenen frekanslarla gözlenen frekansları karşılaştırır. Beklenen frekans (satır toplamı × sütun toplamı) / genel toplam formülüyle bulunur (Stockemer, 2019, s. 126). Varsayalım ki 200 öğretmenin cinsiyeti ile çalıştığı sınıf düzeyini çaprazladınız; erkek öğretmen sayısı 80, birinci düzeydeki toplam öğretmen sayısı 50 ise, o hücrenin beklenen frekansı (80 × 50) / 200 = 20'dir. Gözlenen frekans 10 ise, o hücre sıfır hipotezinin öngördüğünden belirgin biçimde sapıyor demektir. Çapraz tabloda serbestlik derecesi (satır − 1) × (sütun − 1)'dir (Fraenkel ve Wallen, 2009, s. 234). Tek varsayımı kolay denetlenir: **hiçbir hücrede beklenen frekans 5'in altında olmamalıdır**; SPSS bunu tablonun altındaki dipnotta söyler (Field, 2018). Etki büyüklüğü olarak Cramér V, 2×2 tablolarda ayrıca odds oranı raporlanır.

> ÖRNEK **F anlamlı çıktı, sonra ne olacak?** Varsayalım ki dört sınıf düzeyini karşılaştırdınız ve F(3, 196) = 4,72; p = ,003 çıktı. *Kötü örnek:* "Sınıf düzeyleri arasında anlamlı fark bulunmuştur; öz-yeterlik sınıf düzeyi arttıkça artmaktadır." İkinci cümlenin dayanağı yoktur. *İyi örnek:* "Sınıf düzeyine göre anlamlı fark bulunmuştur, F(3, 196) = 4,72; p = ,003; η^2 = ,07. Tukey post hoc testine göre fark yalnızca 1. sınıf (M = 3,42) ile 4. sınıf (M = 3,81) arasındadır; diğer ikili karşılaştırmalar anlamlı değildir." **F, farkın var olduğunu; post hoc, nerede olduğunu söyler.**

Korelasyon birlikte değişimi ölçer; **regresyon** kestirim yapar. Stockemer'in ayrımı akılda kalıcıdır: korelasyonda doğrunun yönüne ve noktaların doğruya yakınlığına bakarız; bu iki değişkenin birlikte değiştiğini gösterir ama bir değişkenin diğerini **ne kadar güçlü etkilediğini** göstermez. Regresyonda ilgilendiğimiz şey eğimin dikliğidir (2019, s. 148). Regresyon denklemi $Y = b_0 + b_1X$ biçimindedir; b_1, X bir birim arttığında Y'nin ne kadar değiştiğini söyler (Marcinkiewicz ve Schnapp, 2021, s. 234). *Örnek:* Varsayalım ki haftalık ders çalışma saatinden tarihsel düşünme puanını kestiriyorsunuz ve denklem $\hat{Y} = 18,4 + 1,2X$ çıktı. Bunun anlamı şudur: haftada bir saat daha çalışan öğrencinin puanı ortalama 1,2 puan daha yüksek. Kesme değeri 18,4 ise "hiç çalışmayan öğrenci"nin kestirilen puanıdır; çoğu zaman içeriksel bir anlamı yoktur ama matematiksel olarak gereklidir. **Nedensellik iddiası hâlâ yoktur:** regresyon bir kestirim aracıdır, deneysel bir kanıt değil.

Şimdi varsayımlara gelelim. Sosyal bilimlerdeki istatistiksel işlemlerin çoğu doğrusal modelin çeşitlemesi olduğu için **ortak bir varsayım kümesini** paylaşırlar. Field bunları dört başlıkta toplar: **toplanabilirlik ve doğrusallık, normallik, varyansların homojenliği, bağımsızlık** (Field, 2018). Bir varsayım çiğnenirse test istatistiği ve p-değeri yanlış olur. Ama hangi varsayımın çiğnenmesinin neyi bozduğu farklıdır: doğrusallık çiğnenirse **model tümüyle geçersizdir**; homojenlik çiğnenirse parametre kestirimi yansız kalır ama **standart hata, dolayısıyla güven aralığı ve p-değeri** bozulur; bağımsızlık çiğnenirse anlamlılık testleri geçersizleşir.

Normallik varsayımı, Türkçe yazında en çok yanlış anlaşılan varsayımdır. **Varsayım, verinin kendisinin normal dağılmasıyla değil, modelin artıklarının ya da ilgili parametrenin örnekleme dağılımının normalliğiyle ilgilidir** (Field, 2018). Örnekleme dağılımına doğrudan erişemediğimiz için veriye bakarız — ama bu bir vekildir, tanımın kendisi değil. İki pratik sonuç: **(1)** Örneklem yeterince büyükse merkezî limit teoremi sayesinde normallik büyük ölçüde sorun olmaktan çıkar. **(2)** Kategorik bir yordayıcı varsa genel dağılıma değil, **yordayıcının her düzeyindeki** dağılıma bakılır (Field, 2018).

Tablo 6.6 · Varsayım denetim listesi

Varsayım	Nasıl bakılır	Çiğnenirse ne bozulur	Ne yapılır
Aykırı değer (sıfırıncı	Histogram, kutu grafiği, z	Kareler toplamı; dolayısıyla	Hataysa düzelt; gerçekse

Varsayım	Nasıl bakılır	Çiğnenirse ne bozulur	Ne yapılır
adım)	puanları	SS, standart hata, GA ve test istatistiği	duyarlılık analizi yap
Doğrusallık	Saçılım grafiği; artıklar–kestirilen değerler grafiği	**Model tümüyle geçersiz olur** (diğerleri karşılansa bile)	Dönüşüm uygula ya da doğrusal olmayan model kur
Normallik (artıkların)	Histogram, Q-Q grafiği, çarpıklık-basıklık; (dikkatle) Shapiro-Wilk	Küçük örneklemde güven aralıkları ve anlamlılık testleri	Örneklem büyükse sorun değil; küçükse parametrik olmayan karşılığa geç
Varyans homojenliği	Levene testi + varyans oranı; standartlaştırılmış artık grafiği	Standart hata yanlı olur → güven aralığı ve p-değeri bozulur	Grup büyüklükleri eşitse önemsiz; değilse Welch düzeltmesi kullan
Bağımsızlık	Desenin mantığı; kümelenme var mı (öğrenciler sınıflarda)?	Standart hata denklemi geçersizleşir → testler geçersiz olur	Çok düzeyli model kur ya da kümelenmeyi desende çöz
Ki-kare: beklenen frekans ≥ 5	SPSS çıktısının altındaki dipnot	Ki-kare istatistiği isabetsiz olur	Kategorileri birleştir ya da Fisher kesin testine geç
Regresyon: çoklu bağlantı yok	VIF ve tolerans; yordayıcılar arası korelasyon matrisi	Katsayılar kararsızlaşır; ilgili değişkenler anlamsız çıkabilir	VIF > 10 ya da tolerans < 0,2 ise değişken çıkar ya da birleştir

Normalliğe nasıl bakılır? Türkçe tezlerdeki yaygın uygulama, yalnızca **Kolmogorov-Smirnov** testine bakıp "p > ,05 olduğu için veri normal dağılmaktadır" yazmaktır. Bu, iki nedenle sorunludur. Birincisi, Kolmogorov-Smirnov ve Shapiro-Wilk testleri **büyük örneklemlerde küçük sapmaları bile anlamlı çıkarır**; Field bu testleri özellikle önermez ve her zaman histogram, P-P/Q-Q grafiği ve çarpıklık-basıklık değerleriyle **birlikte** yorumlanmalarını ister (Field, 2018). İkincisi, Shapiro-Wilk sapmaları saptamada daha güçlüdür; iki testten hangisine bakıldığı sonucu değiştirebilir. **Önerimiz:** dört kanıtı birlikte raporlayın — histogram, Q-Q grafiği, çarpıklık-basıklık ve (istiyorsanız) normallik testi.

Varyansların homojenliği için SPSS **Levene testini** verir. Field'ın uyarısı burada da aynıdır: büyük örneklemlerde önemsiz varyans farkları Levene'i anlamlı çıkarır. Kendi örneğinde erkeklerin varyansı 0,413, kadınlarınki 0,496'dır; oran 1,2'dir, yani varyanslar pratikte eşittir. Buna karşın 315 ve 495 kişilik gruplarda Levene anlamlı çıkar (Field, 2018). Ayrıca kritik bir kolaylık: **grup büyüklükleri eşitse bu varsayımın çiğnenmesi hemen hemen ilgisizdir.** Levene anlamlı çıkarsa yapılacak iş paniklemek değil, çıktıda **"eşit varyans varsayılmadı" satırını** okumaktır (Stockemer, 2019, s. 104).

Varsayımlar gerçekten karşılanmıyorsa üç seçeneğiniz var. **Bir:** Sağlam (robust) alternatifleri kullanın — t-testi yerine Welch düzeltmesi, ANOVA yerine Welch ya da Browne-Forsythe F. Field, Welch F'i her zaman raporlamayı önerir (Field, 2018). **İki:** Parametrik olmayan karşılığa geçin — t-testi yerine Mann-Whitney U, ilişkili t-testi yerine işaret testi ya da Wilcoxon, tek yönlü ANOVA yerine Kruskal-Wallis, ilişkili çok gruplu desende Friedman (Fraenkel ve Wallen, 2009, s. 233). **Üç:** Fraenkel ve Wallen'ın son önerisini uygulayın — veriyi **hem parametrik hem parametrik olmayan** teknikle çözümleyin; sonuçlar tutarlıysa yorumunuz güçlenir, tutarsızsa nedenlerini tartışın (2009, s. 255).

Tablo 6.6 hangi varsayımın çiğnenmesinin **neyi bozduğunu** gösteriyordu. Şimdi bir adım daha atıp aynı soruyu test test soralım: elimdeki testte hangi varsayımı, nasıl denetleyeceğim ve denetim kötü sonuç verirse **tam olarak ne yapacağım**? Aşağıdaki tablo bunu bir karar tablosu olarak verir; Tablo 6.6'nın yerini almaz, onu tamamlar. Tablodaki koşulların kaynağı da bellidir: bağımsız örneklemler t-testi altı koşul ister — bağımlı değişken sürekli olmalı, bağımsız değişken karşılıklı dışlayan gruplardan oluşan kategorik bir değişken olmalı, gözlemler bağımsız olmalı, çok sayıda önemli aykırı değer bulunmamalı (bu koşul örneklem

küçüldükçe sertleşir), bağımlı değişken aşağı yukarı normal dağılmalı ve grupların varyansları benzer olmalıdır (Stockemer, 2019, s. 101).

Tablo 6.9 · Varsayım ihlallerinde karar tablosu

Test	Denetlenecek varsayım	Nasıl denetlenir	İhlal edilirse
Bağımsız örneklemler t	Sürekli bağımlı değişken; kategorik bağımsız değişken; bağımsız gözlem; az aykırı değer; normallik; varyans homojenliği	Histogram, kutu grafiği ve Levene testi	Levene p < ,05 ise çıktının **"eşit varyans varsayılmıyor"** satırı okunur; normallik yoksa Mann-Whitney U'ya geçilir
İlişkili örneklemler t	Fark puanlarının normalliği	Fark puanlarının histogramı	Wilcoxon işaretli sıralar testine geçilir
Tek yönlü ANOVA	Normallik; varyans homojenliği	Histogram ve homojenlik testi	**F'nin kendisi için homojenlik ihlali görece sorunsuzdur;** normallik yoksa Kruskal-Wallis'e geçilir
ANOVA sonrası post hoc	Varyans homojenliği	Options → Homogeneity of Variance Test	p < ,05 ise post hoc menüsünde **"Equal Variances Not Assumed"** altındaki seçenekler; p ≥ ,05 ise "Equal Variances Assumed"
Ki-kare	Her gözede beklenen frekans ≥ 5	Çapraz tabloda beklenen değerler ve çıktının dipnotu	Kategoriler birleştirilir; her kategoride birkaç gözlem bulunmalıdır
Pearson korelasyon ve regresyon	Doğrusallık; eşvaryanslılık; ardışık bağımlılık yok; içsellik yok; eşdoğrusallık yok; N > k	Saçılım grafiği, artık grafiği, VIF	Doğrusal olmayan ilişki uygun işlevsel biçimle modele alınır; yüksek korelasyonlu yordayıcılar birbirinin açıklama gücünü alır ve anlamsızlaşabilir

Tabloyu okuma kuralı. Varsayım ihlali otomatik olarak "parametrik olmayan teste geç" demek değildir. Sıra şudur: önce çıktının düzeltilmiş satırı var mı bakın (t-testinde vardır), sonra değişkeni dönüştürmeyi düşünün, en son parametrik olmayan teste geçin. Nedeni şudur: parametrik olmayan yaklaşımların **istatistiksel gücü düşüktür**; güçlü bir ilişki varken bile onu yakalayamayabilirler ve bağımlı değişken normal dağılıyorsa parametrik testler grup farkını saptamada daha güçlüdür (Singh, 2026, s. 201). Yani parametrik olmayan teste geçmek risksiz bir kaçış değil, bir bedel ödemektir. Örneklem büyüklüğü de bir denetim ölçütüdür: n 100'ün üzerindeyse merkezî limit teoremi gereği örneklem ortalamaları evren normal olmasa bile normale yakınsar ve parametrik test tercih edilir; küçük örneklemlerde parametrik olmayan yaklaşımlar daha uygundur (s. 202). Geçiş yapacaksanız eşleştirme şudur (s. 201): tek örneklem t → Wilcoxon; bağımsız örneklemler t → Mann-Whitney U; ilişkili örneklemler t → Wilcoxon işaretli sıralar; tek yönlü ANOVA → Kruskal-Wallis; tekrarlı ölçümler ANOVA → Friedman. İkili sonuçlu değişkenlerde sırasıyla ki-kare/binom, Fisher kesin testi, McNemar, ki-kare ve Cochran Q kullanılır.

> DİKKAT **Homojenlik F için değil, post hoc için kritiktir.** Öğrencilerin en sık yaptığı hata, varyans homojenliği ihlalini ANOVA'nın tümünü geçersiz kılan bir felaket sanmaktır. Stockemer'in ayrımı nettir: varyans homojenliğinin ihlali, tek yönlü ANOVA'nın **kendisini** yorumlamak açısından görece sorunsuzdur; ancak grup ortalamaları etrafındaki değişkenliğin eşit olup olmaması **ikili karşılaştırma testleri yapılırken önemlidir** (2019, s. 116). Pratik sonuç: homojenlik testi F'den önce değil, **post hoc'tan önce** denetlenir ve sonucu post hoc **seçimini** belirler. *Kötü karar:* "F anlamlı çıktı (p = ,000). Tukey seçtim, çünkü herkes onu kullanıyor." *İyi karar:* "F anlamlı çıktı (p = ,000). Post hoc'a geçmeden önce One-Way ANOVA ekranında **Options → Homogeneity of Variance Test**'i işaretleyip varyans homojenliğini denetledim. Test anlamlı çıktı (p = ,024); yani üç grubun ortalamaları etrafındaki

değişkenlik eşit değil. Bu nedenle Post Hoc menüsünde **"Equal Variances Not Assumed"** başlığı altındaki seçeneklerden birini kullandım. Homojenlik testi anlamsız çıksaydı "Equal Variances Assumed" altındakileri kullanacaktım." (s. 116–117) **Sosyal bilgiler örneği.** Üç öğretim yöntemi (düz anlatım, işbirlikli öğrenme, argümantasyon) ile 8. sınıf T.C. İnkılap Tarihi başarısı karşılaştırılıyor: F(2, 84) = 10,05; p < ,001; homojenlik testi p = ,024 → eşit varyans varsayılmayan post hoc. Sonuç: argümantasyon ile düz anlatım arasındaki 12,4 puanlık fark (p = ,032) ve argümantasyon ile işbirlikli öğrenme arasındaki 9,7 puanlık fark (p = ,041) anlamlı; düz anlatım ile işbirlikli öğrenme arasındaki 2,7 puanlık fark anlamlı değildir (p = ,955). Rapor cümlesinde üç bilgiyi birden yazın: F'nin anlamlılığı, post hoc'un **neden** o seçildiği, hangi ikililerin **kaç puan** farklı olduğu.

ÖRNEK **Üç soru, üç test, üç gerekçe. (1)** "Kavram haritası kullanan ve kullanmayan yedinci sınıf öğrencilerinin tarihsel düşünme puanları farklılaşmakta mıdır?" → Bağımlı değişken sürekli, iki bağımsız grup → **bağımsız örneklemler t-testi**, etki büyüklüğü Cohen d. **(2)** "Aynı öğrencilerin uygulama öncesi ve sonrası puanları farklılaşmakta mıdır?" → Aynı kişiler, iki ölçüm → **ilişkili örneklemler t-testi. (3)** "Öğretmen adaylarının sınıf düzeyine göre (1, 2, 3, 4) öz-yeterlik puanları farklılaşmakta mıdır?" → Dört bağımsız grup → **tek yönlü ANOVA + post hoc**, etki büyüklüğü eta kare.

Bir de sık sorulan bir soru var: kaç tane test yapmalıyım? Cevap, araştırma sorusu sayısı kadardır — daha fazlası değil. Varsayalım ki ölçeğinizin dört alt boyutu var ve bunları cinsiyet, sınıf düzeyi ve okul türüne göre karşılaştırıyorsunuz; bu, on iki ayrı test demektir ve en az bir I. tip hata yapma olasılığınız %45'e yaklaşır. Çözüm, testleri azaltmaktır: alt boyutları tek bir çok değişkenli analizde (MANOVA) birleştirin ya da hangi karşılaştırmaların **kuramsal olarak** gerekli olduğunu önceden yazın. SPSS'te adım adım nasıl yapılır? Bağımsız örneklemler t-testi için: puanları **tek bir sütuna yığın**, ikinci sütuna grup kodunu (1, 2) girin; **Analyze → Compare Means → Independent-Samples T Test**; puan sütununu *Test Variable*, grup sütununu *Grouping Variable* kutusuna taşıyın; **Define Groups** ile 1 ve 2 değerlerini tanımlayın; **OK** (Fraenkel ve Wallen, 2009, s. 231). Çıktıda önce Levene satırına, sonra t, sd ve Sig. değerlerine, sonra ortalama farka ve %95 güven aralığına bakın. Stockemer'in öğretici notu şudur: **iki grubun güven aralıkları büyük ölçüde örtüşüyorsa, p-değerine bakmadan bile grupların farklı olmadığını görebilirsiniz** (2019, s. 110).

ÖRNEK **SPSS çıktısını doğru sırayla okumak.** Varsayalım ki bağımsız örneklemler t-testi çalıştırdınız ve çıktı şu: **Levene:** F = 4,62; p = ,036 → varyanslar eşit değil, o hâlde **"eşit varyans varsayılmadı" satırını** okuyacaksınız. **Güven aralıkları:** deney grubu için [25,6 – 29,4], kontrol grubu için [22,0 – 26,2] → aralıklar kısmen örtüşüyor, demek ki fark büyük değil. **En son p:** t(57,3) = 2,41; p = ,019. *Kötü okuma:* önce p'ye bakıp "anlamlı!" demek. *İyi okuma:* önce Levene'e, sonra aralıklara, en son p'ye bakmak — ve sonuca etki büyüklüğüyle (d = 0,63) birlikte karar vermek.

UYGULAMA **t-testi çıktısını sekiz sütunda okumak.** SPSS'in bağımsız örneklemler t-testi çıktısı **iki tablodan** oluşur (Stockemer, 2019, s. 106–108). Aşağıdaki sırayı bozmayın. **Önce özet tablo.** Grup ortalamalarına ve standart sapmalara bakın. Ortalamalar birbirine yakınsa ve standart sapmalar büyükse, testi çalıştırmadan önce "muhtemelen anlamlı fark yok" tahminini yapabilirsiniz (s. 106). Bu tahmin, çıktıyı yanlış okuduğunuzda sizi uyaracak bir emniyet kemeridir. **Sonra test tablosu, sırayla: (1) 1.–2. sütun · Levene testi.** Varyansların benzerliğini ölçer. Anlamlılık ,05'ten büyükse varsayım ihlal edilmemiştir ve hangi satırı okuduğunuz fark etmez. Küçükse ihlal vardır, ama bu dramatik değildir: **alt satırı, yani "eşit varyans varsayılmıyor" satırını** okursunuz (s. 104–105). **(2) 3. sütun · t değeri.** Büyük t değerleri genellikle grup farkına işaret eder. **(3) 4. sütun · serbestlik derecesi.** Anlamlılığın hesaplanması için gereklidir; yorum açısından ikincildir. **(4) 5. sütun · anlamlılık. t-testini yorumlarken bakılacak en önemli alan budur.** ,05 ölçütüyle ,103 gibi bir değer sıfır hipotezinin reddedilemeyeceğini gösterir (s.

107). **(5) 6. sütun · ortalamalar farkı.** Formülün payı. **(6) 7. sütun · farkın standart hatası.** Formülün paydası. 6. sütunu 7. sütuna bölerseniz t değerini elde edersiniz — çıktıyı doğru okuduğunuzu böyle denetleyin. **(7) 8. sütun · güven aralığı. Aralık sıfırı içeriyorsa sıfır hipotezi reddedilemez** (s. 108). **Sosyal bilgiler örneği.** "Argümantasyon uygulanan şube ile geleneksel anlatım yapılan şubenin harita okuma başarısı farklı mıdır?" Levene p = ,21 (ihlal yok, üst satır), t = 2,84; sd = 50; p = ,006; ortalamalar farkı = 7,2 puan; %95 GA [2,1; 12,3]. Aralık sıfırı içermiyor, fark anlamlıdır. Şimdi etki büyüklüğünü hesaplayın ve Tablo 6.7'deki eşiklere göre yorumlayın.

UYGULAMA **Analiz öncesi altı dakikalık denetim.** Testi çalıştırmadan önce şu altı soruyu yanıtlayın: **(1)** Bağımlı değişkenim hangi düzeyde? **(2)** Kaç grubum var; bağımsız mı, ilişkili mi? **(3)** Histogramı çizdim mi? **(4)** Aykırı değer var mı; hata mı, gerçek mi? **(5)** Grup büyüklüklerim eşit mi (eşitse homojenlik büyük ölçüde sorun değil)? **(6)** Hangi etki büyüklüğünü raporlayacağım? Altı sorunun cevabı yoksa test çalıştırmayın — çalıştırırsanız çıktıyı yorumlayamazsınız.

6.5 · Yorumlama: p, Etki Büyüklüğü ve Raporlama

Bu bölümün başlığındaki soru, dersin bu haftaki büyük sorusudur: "anlamlı çıktı" ne demek, ne demek değil? Cevabın en yetkili özeti, Amerikan İstatistik Derneği'nin (ASA) 2016'da yayımladığı p-değeri açıklamasıdır. Bu, derneğin kurumsal politika olarak yayımladığı ilk açıklamadır ve altı ilke içerir (Wasserstein ve Lazar, 2016). Altısını da sırayla vereceğiz, çünkü her biri tezinizde yazacağınız bir cümleyi doğrudan değiştirir.

İlke 1: p-değerleri, verinin belirli bir istatistiksel modelle ne ölçüde bağdaşmadığını gösterebilir. Buradaki "model" yalnızca sıfır hipotezi değildir; onunla birlikte varsayılan her şeyi — dağılım, bağımsızlık, ölçüm, örnekleme — içerir. Küçük bir p, bu bütünden herhangi birinin yanlış olabileceğini gösterir. **İlke 2: p-değeri, incelenen hipotezin doğru olma olasılığını ya da verinin yalnızca rastlantıyla üretilmiş olma olasılığını ölçmez.** p = ,03 bulmak, "sıfır hipotezinin doğru olma olasılığı %3'tür" demek **değildir**; p, hipotez doğru varsayıldığında verinin olasılığıyla ilgilidir (Wasserstein ve Lazar, 2016).

İlke 3: Bilimsel sonuçlar ve kararlar, yalnızca bir p-değerinin belirli bir eşiği geçip geçmediğine dayandırılmamalıdır. Field bunun ne kadar keyfî olduğunu tek bir karşılaştırmayla gösterir: p = ,0499 ile p = ,0501 aynı büyüklükte bir etkiyi yansıtır, ama NHST reçetesi biri için "anlamlı", öteki için "anlamsız" der (Field, 2018). **İlke 4: Doğru çıkarım, eksiksiz raporlama ve şeffaflık gerektirir.** Kaç hipotez sınandığı, hangi çözümlemelerin yapıldığı, hangi kararların veriye bakıldıktan sonra alındığı bildirilmelidir. Yalnızca anlamlı çıkanı raporlamak, raporlanan p-değerini yorumlanamaz kılar (Wasserstein ve Lazar, 2016).

İlke 5: Bir p-değeri ya da istatistiksel anlamlılık, bir etkinin büyüklüğünü ya da bir sonucun önemini ölçmez. Bu, bu haftanın en önemli cümlesidir. **İlke 6: p-değeri, tek başına, bir model ya da hipoteze ilişkin kanıtın iyi bir ölçüsünü sağlamaz;** etki büyüklüğü, güven aralığı, önsel bilgi, desen ve yineleme kanıtıyla birlikte yorumlanmalıdır (Wasserstein ve Lazar, 2016). ASA, tamamlayıcı yaklaşımlara da işaret eder: güven aralıkları, olabilirlik oranları, Bayes faktörleri, yanlış keşif oranları.

BİLGİ **ASA'nın altı ilkesi — tam liste. 1.** p-değerleri, verinin belirli bir istatistiksel modelle ne ölçüde bağdaşmadığını gösterebilir. **2.** p-değerleri, incelenen hipotezin doğru olma olasılığını ya da verinin yalnızca rastlantıyla üretilmiş olma olasılığını ölçmez. **3.** Bilimsel sonuçlar ile iş ya da politika kararları, yalnızca bir p-değerinin belirli bir eşiği geçip geçmediğine dayandırılmamalıdır. **4.** Doğru çıkarım, eksiksiz raporlama ve şeffaflık gerektirir. **5.** Bir p-değeri ya da istatistiksel anlamlılık, bir etkinin büyüklüğünü ya da bir sonucun önemini ölçmez. **6.** Bir p-değeri, tek başına, bir model ya da hipoteze ilişkin kanıtın iyi bir ölçüsünü sağlamaz. (Wasserstein ve Lazar, 2016)

İlke 5'in ne kadar ciddi olduğunu bir sayı çiftiyle görün. Field'ın gösteriminde şarkı söyleyen grubun ortalaması 10,00 (SS = 3), sohbet eden grubunki 10,01 (SS = 3)'tür. Fark **0,01**'dir. Grup başına 1.000.000 kişi olduğunda p = **,044** çıkar; yani "anlamlı". Aynı veri için Cohen d = **−0,003**'tür (Field, 2018). Aynı gösterimin tersi de doğrudur: ortalamalar 10 ve 12, standart sapmalar 3 iken grup başına 10 kişiyle p = ,15 (anlamsız), 100 kişiyle p < ,001 (yüksek düzeyde anlamlı) çıkar. İki durumda da **d = −0,667**'dir. p değişti, etki değişmedi.

Etki büyüklüğü, gözlenen etkinin büyüklüğünün nesnel ve genellikle standartlaştırılmış ölçüsüdür. Standartlaştırılmış olması, farklı ölçekler kullanan çalışmaların karşılaştırılmasını sağlar (Field, 2018). En yaygın üçü Cohen d, Pearson r ve odds oranıdır. **Cohen d**, iki ortalama arasındaki farkın standart sapmaya bölünmesiyle elde edilir; sonuç "fark, kaç standart sapma kadar?" sorusunun cevabıdır. Cohen'in uzlaşımsal eşikleri d = 0,20 küçük, 0,50 orta, 0,80 büyüktür (Cohen, 1988, s. 25–26).

Diğer göstergeler de aynı mantıkla okunur. **Pearson r** için Cohen'in eşikleri ,10 küçük (varyansın %1'i), ,30 orta (%9'u), ,50 büyüktür (%25'i) (Cohen, 1988, s. 79–80). **Eta kare (η^2)**, ANOVA'da açıklanan varyans oranıdır ve Cohen'in eşikleri ,01 küçük, ,06 orta, ,14 büyüktür (Cohen, 1988, s. 281). Fraenkel ve Wallen'ın kendi ölçütü daha kabadır ama işe yarar: çoğu araştırmacı **,50 ya da daha büyük** bir etki büyüklüğünü önemli bir bulgu sayar (2009, s. 244).

Tablo 6.7 · Etki büyüklüğü göstergeleri ve yorum eşikleri

Gösterge	Nerede kullanılır	Küçük	Orta	Büyük	Not
Cohen d	İki ortalama karşılaştırması (t-testi)	0,20	0,50	0,80	Fark, kaç standart sapma kadar?
Pearson r	İki sürekli değişken arasındaki ilişki	,10	,30	,50	Varyansın sırasıyla %1, %9, %25'i
Eta kare (η^2)	Tek yönlü ANOVA	,01	,06	,14	Açıklanan toplam varyans oranı
Kısmi eta kare (η^2_p)	Çok faktörlü ANOVA / ANCOVA	—	—	—	**Cohen'in eşikleri bunun için tanımlanmadı;** η^2'den sistematik olarak büyüktür
f^2	Çoklu regresyon	,02	,15	,35	Cohen'in kendi çekincesiyle birlikte kullanılır
Cramér V	Ki-kare (çapraz tablo)	—	—	—	0–1 arası; korelasyon gibi okunur
Odds oranı	2×2 çapraz tablo	—	—	—	1 = fark yok; 1/OR ile ters yöne çevrilir
Fraenkel ve Wallen ölçütü	İki grup karşılaştırması	—	—	≥ ,50	"Çoğu araştırmacı ,50 ve üstünü önemli sayar"

DİKKAT **Kısmi eta kare tuzağı.** SPSS'in ANOVA çıktısındaki **Partial Eta Squared** sütunu ile Cohen'in ,01/,06/,14 eşikleri **aynı ölçüte ait değildir.** Cohen'in eşikleri **eta kare** içindir; kısmi eta karenin paydasında toplam varyans değil, yalnızca ilgili etki ile hata varyansının toplamı bulunur. Çok faktörlü desenlerde kısmi eta kare her zaman daha büyüktür. **Yapılacak iş:** (1) hangi ölçütü raporladığınızı adıyla yazın (η^2 mi, η^2_p mi); (2) eşikleri "Cohen'in η^2 için önerdiği ölçütler" diyerek verin; (3) tek faktörlü desende ikisi eşit olduğundan sorun yoktur, karışıklık çok faktörlü desende doğar.

Şimdi Türkçe yazında en sık düşülen teknik tuzağa geliyoruz: **kısmi eta kare.** Cohen'in ,01/,06/,14 eşikleri **eta kare** için tanımlanmıştır. SPSS'in ANOVA çıktısında verdiği ölçüt ise **kısmi eta karedir** (η^2_p) ve paydası farklıdır: toplam varyans yerine yalnızca ilgili etki ile hata varyansının toplamı kullanılır. Çok faktörlü desenlerde kısmi eta kare, eta kareden **sistematik olarak büyüktür.** Cohen'in eşiklerini kısmi eta kareye doğrudan uygulamak, bu yüzden etkiyi abartır. Alanyazın bu eşikleri kısmi eta kare için de rutin olarak

kullanır; **ama bu yaygın uygulama Cohen'in özgün tanımına dayanmaz.** Tezinizde hangisini raporladığınızı açıkça yazın.

Etki büyüklüğü eşikleri de mutlak değildir. Sayısal bir hatırlatma: Cohen'in η^2 için verdiği ,01/,06/,14 değerleri, ANOVA etki büyüklüğü f için verdiği ,10/,25/,40 değerlerinden türetilmiştir (Cohen, 1988, s. 281); yani eşikler birbirinden bağımsız olarak değil, tek bir mantıkla üretilmiştir. Cohen bu değerleri, alanın kendi ampirik birikimi olmadığında başvurulacak **son çare uzlaşımları** olarak sunmuştur (Cohen, 1988). Field, Cohen'in kendisinin bu ölçütlerin tam da kaçınmaya çalıştığımız tembel düşünmeyi özendirdiğini kabul ettiğini aktarır (Field, 2018). Doğru ilke şudur: **etki büyüklüğü, alanın kendi dağılımına göre yorumlanır.** 0,50'lik bir d bir alanda kayda değer, başka bir alanda önemsiz olabilir. Bu yüzden APA, etki büyüklüklerini daha önce raporlanmış araştırmalar bağlamında yorumlamayı ister (Wilkinson ve APA Task Force on Statistical Inference, 1999).

İstatistiksel anlamlılık ile pratik anlamlılık ayrı şeylerdir. Fraenkel ve Wallen'ın üç örneği bunu somutlaştırır: iki bölgeden 1.000'er lise atıcısının top hızları arasındaki 4 mil/saatlik fark istatistiksel olarak anlamlı olabilir, ama hiçbir taraftar bunu önemli saymaz. Yeni bir yöntemle öğretilen öğrencilerin final sınavında **iki puan** yüksek alması istatistiksel olarak anlamlı olabilir, ama bir bölümün bütün öğretim biçimini değiştirmesini gerektirmez (2009, s. 226–227). Tersi de doğrudur: erken müdahalenin zekâ puanını ortalama 12 puan artırdığı ama ,05 düzeyinde anlamlı çıkmadığı bir bulgu **hatırı sayılır ilgiyi hak eder**; büyük olasılıkla örneklem küçüktür (2009, s. 254).

> ÖRNEK **Anlamlı ama önemsiz / anlamsız ama önemli. Anlamlı ama önemsiz:** Fraenkel ve Wallen'ın örneğinde öğretmen cinsiyeti ile sınıf düzeyi arasındaki ilişki için $\chi^2 = 16{,}66$ ve kontenjans katsayısı C = ,28 bulunur. 3 serbestlik derecesiyle kritik değer 7,81 olduğu için sonuç **istatistiksel olarak anlamlıdır**; ama ,28'lik bir ilişki pratikte önemsizdir (2009, s. 253). **Anlamsız ama önemli:** Bir erken müdahale programının zekâ puanını ortalama 12 puan artırdığı bulunuyor ama sonuç ,05 düzeyinde anlamlı değil. 12 puan çoktur; yinelemelerde doğrulanırsa çok önemli olabilir. Görünen o ki örneklem küçüktü (2009, s. 254).

Sonuçları nasıl raporlayacaksınız? APA'nın kuralı ile Field'ın önerdiği biçim örtüşür ve dört parçadan oluşur: **bulguyu sözle söyleyin → betimsel değerleri verin → test istatistiğini serbestlik derecesiyle birlikte yazın → tam p-değeri ve etki büyüklüğünü ekleyin.** Field iki noktayı özellikle vurgular: **tam p-değerleri raporlanmalıdır** ($p < ,05$ değil, $p = ,023$); ve güven aralıkları köşeli parantez içinde, türü belirtilerek verilmelidir (Field, 2018). Tek istisna çok küçük değerlerdir: $p = ,0000234$ bulduğunuzda yer ve akıl sağlığı adına $p < ,001$ yazmak makuldür. APA 7 ayrıca 1'i aşamayan değerlerde ondalık öncesi sıfırı düşürür: $p = ,023$; $r = ,44$ (American Psychological Association, 2020). APA'nın nicel raporlama standardı JARS-Quant ise bir adım daha ileri gider ve hipotezlerin **birincil, ikincil ve keşfedici** olarak ayrılmasını ister (Appelbaum ve ark., 2018); bu ayrım, hangi bulgunun önceden planlandığını hangisinin veriye bakarken doğduğunu okura açıkça gösterir.

Türkçe yazında en sık görülen üç raporlama hatası şunlardır ve üçünün de çaresi tek bir cümlededir. **(1) "p < ,05 olduğu için fark anlamlıdır"** deyip büyüklüğü hiç söylememek. **(2) Etki büyüklüğünü hiç raporlamamak** — oysa APA'nın kararı 1999'dan beri nettir: bir p-değeri raporlanırken her zaman bir etki büyüklüğü kestirimi de verilmelidir (Wilkinson ve APA Task Force on Statistical Inference, 1999). **(3) Normallik için yalnızca Kolmogorov-Smirnov'a bakmak.** Çaresi: her bulgu cümlesini "test istatistiği + sd + tam p + etki büyüklüğü + güven aralığı" dörtlüsüyle kurmak. Büyüköztürk'ün Türkçe tezlerde yerleşmiş raporlama biçimi de bu sırayı izler (Büyüköztürk, 2025).

Tablo 6.8 · Kötü cümle / iyi cümle: raporlama çiftleri

Durum	Kötü örnek	İyi örnek	Neden
t-testi anlamlı	“Gruplar arasında p<0,05 düzeyinde anlamlı fark bulunmuştur.”	“Deney grubunun ortalaması (M = 27,5; SS = 5,3) kontrol grubundan (M = 24,1; SS = 5,5) yüksektir, t(58) = 2,41; p = ,019; d = 0,63.”	Tam p, betimsel değerler ve etki büyüklüğü verilmiştir
t-testi anlamsız	“Gruplar arasında fark yoktur.”	“Bu örneklemle anlamlı fark bulunamamıştır, t(398) = 1,51; p = ,132; d = 0,15.”	Anlamsız sonuç, etkinin sıfır olduğu anlamına gelmez
ANOVA anlamlı	“Sınıf düzeyleri arasında fark vardır; puan sınıfla birlikte artmaktadır.”	“F(3, 196) = 4,72; p = ,003; η^2 = ,07. Tukey testine göre fark yalnızca 1. ile 4. sınıf arasındadır.”	F, farkın nerede olduğunu söylemez; post hoc söyler
Korelasyon	“Değişkenler arasında yüksek düzeyde anlamlı ilişki vardır (p<0,01).”	“İki değişken arasında orta düzeyde negatif ilişki bulunmuştur, r = −,44; p < ,001; %95 GA [−,56, −,30].”	Yön, büyüklük ve belirsizlik birlikte verilmiştir
Normallik	“Kolmogorov-Smirnov testi anlamlı olmadığından veriler normal dağılmaktadır.”	“Çarpıklık (−,32) ve basıklık (,41) değerleri ±1 aralığındadır; histogram ve Q-Q grafiği de normalliği desteklemektedir.”	Tek bir teste değil, dört kanıta dayanılmıştır
Pratik anlamlılık	“Sonuç anlamlı olduğundan yöntemin kullanılması önerilir.”	“40 puanlık test üzerinden 3,4 puanlık fark orta düzeyde bir etkidir (d = 0,63); yaygınlaştırma kararı için yineleme çalışmaları gereklidir.”	İstatistiksel anlamlılık, pratik anlamlılık demek değildir

ÖRNEK **Sonuç cümlesi nasıl yazılır: dört kötü / iyi çift. 1 · Anlamlı olmayan t-testi.** *Kötü:* “Gruplar arasında anlamlı fark bulunamamıştır; hipotez doğrulanmamıştır.” *İyi:* “Erkeklerin daha yüksek puan alacağı yönündeki hipotez desteklenmemiştir. Ortalamalar beklenenin tersi yöndedir (kızlar 79, erkekler 73); ancak 6 puanlık bu fark sıfırdan istatistiksel olarak farklı değildir (p = ,53). Dolayısıyla iki grubun örüntüsü benzerdir.” (Kalıp: Stockemer, 2019, s. 111) — **2 · Anlamlı ANOVA.** *Kötü:* “ANOVA anlamlı çıkmıştır, gruplar farklıdır.” *İyi:* “Genel F testi gruplar arasında fark olduğunu göstermektedir (p = ,0003). Ancak F testi farkın nerede olduğunu söylemez. Varyansların eşitliği testi anlamlı olduğundan (p = ,001), çoklu karşılaştırma eşit olmayan varyans varsayımıyla yürütülmüştür. Buna göre 1. ve 3. gruplar (fark = 43 puan; p = ,032) ile 2. ve 3. gruplar (fark = 39,5 puan; p = ,041) arasındaki farklar anlamlı; 1. ve 2. gruplar arasındaki 3,5 puanlık fark anlamsızdır (p = ,955).” (s. 124) — **3 · Anlamlı olmayan ki-kare.** *Kötü:* “Ki-kare testi ilişki olmadığını kanıtlamıştır.” *İyi:* “Pearson ki-kare değeri 0,382; anlamlılık düzeyi ,536'dır ve bu değer ,05 ölçütünün çok üzerindedir. Sıfır hipotezi reddedilememektedir; yani iki değişkenin dağılımları arasında saptanabilir bir farklılık yoktur. Ki-kare testinin yalnızca farkın **varlığını** gösterdiği, **yerini** göstermediği unutulmamalıdır.” (s. 127–128) Ki-karenin üç sınırlılığını da cümlenize taşıyın: hiçbir gözenin **beklenen** frekansı 5'ten küçük olamaz, büyük örneklemler anlamlı sonuç üretmeye daha yatkındır ve test farkın yerini söylemez — yeri görmek için gözlenen ile beklenen arasındaki farkın en büyük olduğu gözeye bakılır (s. 127). — **4 · Regresyon.** *Kötü:* “Model anlamlıdır; bütün değişkenler bağımlı değişkeni etkilemektedir.” *İyi:* “Yedi yordayıcıdan ikisi anlamlıdır ve beklenen yönde etki göstermektedir. Ders dışı etkinlik değerlendirmesindeki her bir puanlık artış, haftalık harcamada 59 sentlik bir azalmayla ilişkilidir. ,05 ölçütü kullanıldığında diğer değişkenler anlamlı değildir; sıfırdan farklı olmadıkları için **katsayıları yorumlanmaz**. Model uyumu açısından yedi bağımsız değişken, bağımlı değişkendeki varyansın %57'sini açıklamaktadır (R^2 = ,573).” (s. 170) Regresyonda cümlenizi yazmadan önce OLS varsayımlarını da denetleyin — özellikle **ihmal edilmiş değişken** yokluğunu: ihmal edilmiş bir değişken parametreleri yanlı kılar, hata varyansını bozar, güven aralıklarını ve hipotez testlerini güvenilmez hâle getirir ve R^2'yi güvenilmez kılar (s. 172). — **Dört çiftin ortak dersi.** İyi cümlelerin hepsi

aynı dört bileşeni taşır: (a) hipotezle ya da soruyla açık bağ, (b) betimsel değerler (ortalama, fark, yüzde), (c) test istatistiği ve p, (d) bulgunun **sözel yorumu** — farkın yönünün ne anlama geldiği. "Anlamlı çıktı" ya da "anlamlı çıkmadı" tek başına bir sonuç cümlesi değildir.

Peki bu kadar uyarıdan sonra "anlamlı" sözcüğünü hiç kullanmayacak mıyız? Kullanacağız — ama tek başına değil. Fraenkel ve Wallen'ın önerisi nettir: istatistiksel anlamlılık testlerini **yalnızca genellenebilirliği** değerlendirmek için kullanın; ilişkinin ya da farkın büyüklüğünü değerlendirmek için değil (2009, s. 255). Seçkisiz örneklem kullanmadıysanız — ki eğitim araştırmalarının çoğunda durum budur — olasılıkları kesin değerler olarak değil **kaba göstergeler** olarak yorumlayın ve mümkün olan her yerde anlamlılık düzeyi yerine ya da ona ek olarak **güven aralığı** raporlayın. Son olarak, bütün bu tartışmanın neden bu kadar ciddiye alındığını hatırlatalım. Üç büyük psikoloji dergisinde yayımlanmış 100 çalışmanın doğrudan yinelenmesiyle yürütülen projede, anlamlı bulgu raporlayan 97 çalışmadan yalnızca **35'i** yinelemede de anlamlı sonuç vermiştir (Schmidt, 2021, s. 241). Buna karşılık, kriz anlatısına da eleştirel bakmayı öğrenin: p-hacking'in izi sayılan bulguların bir bölümü, daha iyi modellerle incelendiğinde buharlaşmaktadır (Field, 2018). Sizden istenen şey paniklemek değil; **kaç hipotez sınadığınızı, hangi kararı ne zaman aldığınızı ve etkinin ne kadar büyük olduğunu açıkça yazmaktır.**

ÖRNEK **Aynı bulgu, kötü cümle ve iyi cümle.** *Kötü:* "Yapılan analiz sonucunda gruplar arasında p<0.05 düzeyinde anlamlı fark bulunmuştur." *İyi:* "Kavram haritası kullanan grubun son test ortalaması (M = 27,5; SS = 5,3; n = 30), kullanmayan gruptan (M = 24,1; SS = 5,5; n = 30) yüksek bulunmuştur, t(58) = 2,41; p = ,019; d = 0,63; %95 GA [0,61 – 6,19]. Cohen'in ölçütlerine göre orta düzeyde bir etkidir; 40 puanlık test üzerinden 3,4 puanlık bu fark, bir öğretim uygulamasını değiştirmek için tek başına yeterli sayılmamalıdır." İkinci cümle bulguyu, büyüklüğü ve belirsizliği birlikte verir.

Ana Noktalar

ANALİZDEN ÖNCE: VERİYİ TANIMAK

- Veri dosyasının dilbilgisi tektir: her satır bir birey, her sütun bir değişken.
- Kayıp veri iki türlüdür: birim yanıtsızlığı (kişi hiç katılmamış) ve madde yanıtsızlığı (soru boş bırakılmış); ikisi farklı karar gerektirir.
- Aykırı değer ya hatadır (düzeltilir) ya gerçek uç gözlemdir (silinmez, duyarlılık analizi yapılır).
- Aykırı değer kestirimden çok kareler toplamını bozar; bu da standart sapmayı, standart hatayı ve güven aralığını bozar.
- Dört ölçek düzeyi hangi analizin yapılabileceğini belirler: sınıflama, sıralama, eşit aralıklı, oran.
- Kaç vakayla başladığınızı ve kaç vakayla analiz yaptığınızı yazmak zorunludur.

BETİMSEL İSTATİSTİK

- Bir dağılım üç soruyla tanınır: merkez nerede, ne kadar yayılmış, biçimi nasıl?
- Ortalama tüm bilgiyi kullanır ama uç değerlerden aşırı etkilenir; çarpık dağılımda medyan daha isabetlidir.
- Merkezî eğilim asla yayılım olmadan raporlanmaz: n, ortalama ve standart sapma birlikte verilir.
- Aynı ortalamaya sahip iki grup taban tabana zıt dağılımlara sahip olabilir.
- Çarpıklık simetriden sapmayı, basıklık kuyruklarda kümelenmeyi ölçer; ikisi de tek başına değil histogramla birlikte okunur.
- Sayıdan önce grafik gelir: frekans poligonu, histogram, kutu grafiği, saçılım grafiği.
- Korelasyon katsayısına saçılım grafiğine bakmadan güvenilmez.

ÇIKARIMSAL İSTATİSTİĞİN MANTIĞI

- Çıkarımsal istatistik, örneklemden evrene çıkarım yapmayı sağlar; örneklem sonuçlarının büyüklüğünü değerlendirmez.
- Merkezî limit teoremi sayesinde örneklem büyüdükçe (yaklaşık n ≥ 30) örnekleme dağılımı normale yaklaşır.
- Standart hata küçüldükçe kestirim keskinleşir; n arttıkça standart hata küçülür.
- Güven aralığı tek bir aralığa değil, uzun dönemli bir yönteme ilişkin bir orandır.
- I. tip hata var olmayan etkiyi bulmak, II. tip hata var olan etkiyi kaçırmaktır; ikisi takas içindedir.
- İstatistiksel güç 1 − β'dır; hedef ,80 ve güç analizi veri toplamadan önce yapılır.
- On bağımsız test yapılırsa en az bir I. tip hata olasılığı %40'a çıkar.

TEST SEÇİMİ VE UYGULAMA

- Test seçimi üç bilgiyle yapılır: soru türü, ölçek düzeyi, grup sayısı ve bağımlılık durumu.
- F testi hangi grupların farklı olduğunu söylemez; post hoc analiz gerekir.
- Doğrusal modelin dört varsayımı: doğrusallık, normallik, varyans homojenliği, bağımsızlık.
- Normallik varsayımı verinin değil, artıkların ya da örnekleme dağılımının normalliğiyle ilgilidir.
- Kolmogorov-Smirnov ve Levene testleri büyük örneklemlerde önemsiz sapmaları anlamlı çıkarır; tek başlarına kullanılmazlar.
- Varsayım karşılanmazsa üç yol vardır: sağlam alternatif, parametrik olmayan karşılık, ya da iki yöntemle birden çözümleyip karşılaştırmak.
- İhlal sırası bellidir: önce çıktının düzeltilmiş satırı, sonra dönüşüm, en son parametrik olmayan test — çünkü parametrik olmayan testlerin istatistiksel gücü düşüktür.
- Varyans homojenliği ihlali ANOVA'nın kendisi için görece sorunsuzdur; asıl kritik olduğu yer post hoc testinin seçimidir.
- t-testi çıktısı sekiz sütunda okunur; Levene anlamlıysa alt satır, yani “eşit varyans varsayılmıyor” satırı okunur ve güven aralığı sıfırı içeriyorsa sıfır hipotezi reddedilemez.

YORUMLAMA

- ASA'nın altı ilkesi p-değerinin ne olduğunu ve ne olmadığını tanımlar.
- p, etkinin büyüklüğünü ya da sonucun önemini ölçmez; örneklem büyüklüğünden etkilenir.
- Aynı veride n değiştirilerek p taban tabana zıt sonuçlar verebilir; etki büyüklüğü değişmez.
- Cohen'in eşikleri son çare uzlaşımlarıdır; etki büyüklüğü alanın kendi dağılımına göre yorumlanır.
- Kısmi eta kare, eta kareden sistematik olarak büyüktür; Cohen'in eşikleri eta kare için tanımlanmıştır.
- Her bulgu cümlesi dört parçalıdır: betimsel değerler, test istatistiği ve sd, tam p, etki büyüklüğü (ve mümkünse güven aralığı).
- İstatistiksel anlamlılık ile pratik anlamlılık ayrı sorulardır ve ayrı cümlelerle yanıtlanır.
- İyi bir sonuç cümlesi dört bileşenlidir: hipotezle bağ, betimsel değerler, test istatistiği ve p, farkın yönünün sözel yorumu.
- Ki-kare farkın yalnızca varlığını gösterir, yerini göstermez; regresyonda anlamlı olmayan katsayılar yorumlanmaz.

Anahtar Terimler

- **ANCOVA** — Gruplar arasındaki başlangıç farkını bir kovaryantla düzelterek ortalamaları karşılaştıran analiz.
- **Anlamlılık düzeyi (alfa)** — Sıfır hipotezini reddetmek için önceden belirlenen olasılık eşiği.
- **ANOVA** — İkiden çok grubun ortalamalarını bir F değeriyle karşılaştıran analiz.
- **Aykırı değer** — Dağılımın geri kalanından belirgin biçimde uzak duran gözlem.
- **Basıklık** — Puanların dağılımın kuyruklarında ne ölçüde kümelendiği.

- **Betimsel istatistik** — Çok sayıda puanı birkaç özet göstergeyle betimleyen işlemler.
- **Bonferroni düzeltmesi** — Alfanın karşılaştırma sayısına bölünmesiyle yapılan çoklu karşılaştırma düzeltmesi.
- **Cohen d** — İki ortalama arasındaki farkın standart sapma birimiyle ifadesi.
- **Çarpıklık** — Bir dağılımın simetriden sapma ölçüsü.
- **Çıkarımsal istatistik** — Örneklem bulgusundan evren hakkında çıkarım yapmayı sağlayan işlemler.
- **Eta kare (η^2)** — ANOVA'da bağımsız değişkenin açıkladığı toplam varyans oranı.
- **Etki büyüklüğü** — Gözlenen etkinin büyüklüğünün standartlaştırılmış ölçüsü.
- **Güç (istatistiksel)** — Evrende var olan bir etkiyi bulabilme olasılığı ($1 - \beta$).
- **Güven aralığı** — Evren parametresinin makul biçimde içinde bulunabileceği aralık.
- **I. tip hata** — Doğru olan bir sıfır hipotezini reddetmek.
- **II. tip hata** — Yanlış olan bir sıfır hipotezini reddetmemek.
- **Kısmi eta kare (η^2_p)** — Diğer değişkenlerce açıklanmayan varyansın ne kadarının açıklandığını gösteren ölçüt.
- **Ki-kare (χ^2)** — Kategorik veride beklenen ve gözlenen frekansları karşılaştıran test.
- **Levene testi** — Grupların varyanslarının benzer olup olmadığını sınayan test; anlamlı çıkarsa çıktının "eşit varyans varsayılmıyor" satırı okunur.
- **Merkezî limit teoremi** — Örneklem büyüdükçe örnekleme dağılımının normale yaklaşması.
- **Normallik varsayımı** — Artıkların ya da parametrenin örnekleme dağılımının normal olması koşulu.
- **Ortalamalar farkı** — İki grubun ortalamaları arasındaki ham fark; t değerinin payını oluşturur.
- **Ölçek düzeyi** — Bir değişkenin sınıflama, sıralama, eşit aralıklı ya da oran düzeyinde ölçülmesi.
- **Örnekleme dağılımı** — Aynı evrenden çekilen örneklemlerin istatistiklerinin dağılımı.
- **Örnekleme hatası** — Örneklem ile evren arasındaki kaçınılmaz fark.
- **Parametrik olmayan test** — Evrenin dağılımı hakkında az varsayım yapan ya da hiç yapmayan test.
- **Post hoc test** — Veri toplandıktan sonra yapılan ikili grup karşılaştırması.
- **p-değeri** — Sıfır hipotezi doğruyken elde edilen kadar ya da daha uç bir sonuç elde etme olasılığı.
- **Regresyon** — Bir sonucun bir ya da daha çok yordayıcıdan kestirildiği doğrusal model.
- **Sıfır hipotezi** — Evrende ilişki ya da fark bulunmadığını belirten karşılaştırma hipotezi.
- **Standart hata** — Örnekleme dağılımının standart sapması.
- **Sonuç cümlesi** — Bulguyu hipotezle bağ, betimsel değerler, test istatistiği ve sözel yorum olmak üzere dört bileşenle aktaran cümle.
- **Varsayım ihlali** — Bir testin gerektirdiği koşulun karşılanmaması ve buna bağlı olarak düzeltilmiş satır, dönüşüm ya da parametrik olmayan karşılığa geçilmesi.
- **Varyansların homojenliği** — Karşılaştırılan grupların varyanslarının benzer olması koşulu.

Kendini Sına

- **1.** 5'li Likert ölçeğiyle toplanan bir veri dosyasında bir hücrede 44 değeri görülüyor. Bu değerle ilgili en uygun işlem hangisidir?
- a) Değer silinir ve o satır analizden çıkarılır
- b) Ham forma dönülür; büyük olasılıkla 4 olduğu için düzeltilir
- c) Değer olduğu gibi bırakılır çünkü veriye müdahale edilemez
- d) Ortalama ile değiştirilir
- e) Değişken sıralama düzeyine dönüştürülür
- **Doğru:** b · *Ölçeğin üst sınırını aşan bir değer bir giriş hatasıdır; hata düzeltilir, silinmez (Alt başlık 6.1).*
- **2.** "Öğretmenlerin branş değişkeninin ortalaması 2,3'tür" cümlesinin temel sorunu nedir?

- a) Standart sapma verilmemiştir
- b) Ortalama yerine medyan verilmeliydi
- c) Branş sınıflama düzeyinde olduğu için ortalaması anlamsızdır
- d) Örneklem büyüklüğü belirtilmemiştir
- e) Değer çok küçüktür
- **Doğru:** c · *Sınıflama düzeyinde sayılar yalnızca etikettir; ortalama hesaplanamaz (Alt başlık 6.1).*
- **3.** Bir dağılımda ortalama 96, medyan 70'tir. Bu farkın en olası açıklaması nedir?
- a) Örneklem çok büyüktür
- b) Ölçek güvenilir değildir
- c) Dağılımda yüksek uçta bir ya da birkaç uç değer vardır
- d) Standart sapma sıfırdır
- e) Veri sınıflama düzeyindedir
- **Doğru:** c · *Ortalama uç değerlerden aşırı etkilenir; medyan etkilenmez (Alt başlık 6.2).*
- **4.** Aşağıdaki cümlelerden hangisi %95 güven aralığının **doğru** yorumudur?
- a) Bu aralığın evren ortalamasını içerme olasılığı %95'tir
- b) Evren ortalamasının %95'i bu aralıktadır
- c) Çalışma çok kez yinelenip her seferinde aralık kurulsaydı, bu aralıkların yaklaşık %95'i evren ortalamasını içerirdi
- d) Örneklem ortalamalarının %95'i bu aralıktadır
- e) Sonuç %95 olasılıkla doğrudur
- **Doğru:** c · *%95, tek bir aralığa değil uzun dönemli bir yönteme ilişkin bir orandır (Alt başlık 6.3).*
- **5.** Gerçekte var olan bir etkinin bulunamaması hangi hatadır ve hangi kavramla doğrudan ilişkilidir?
- a) I. tip hata; anlamlılık düzeyi
- b) II. tip hata; istatistiksel güç
- c) I. tip hata; etki büyüklüğü
- d) II. tip hata; örnekleme hatası
- e) Ölçme hatası; güvenirlik
- **Doğru:** b · *Var olan etkiyi kaçırmak II. tip hatadır; güç 1 − β'dır (Alt başlık 6.3).*
- **6.** Bir araştırmacı dört farklı sınıf düzeyindeki öğretmen adaylarının öz-yeterlik puanlarını karşılaştırmak istiyor. Uygun test ve zorunlu izleyen adım hangisidir?
- a) Bağımsız örneklemler t-testi; etki büyüklüğü
- b) Ki-kare; Cramér V
- c) Tek yönlü ANOVA; post hoc analiz
- d) Pearson korelasyonu; regresyon
- e) İlişkili örneklemler t-testi; Levene testi
- **Doğru:** c · *Üç ve daha çok bağımsız grup için ANOVA kullanılır; F hangi grupların farklı olduğunu söylemediği için post hoc gerekir (Alt başlık 6.4).*
- **7.** Normallik varsayımıyla ilgili aşağıdakilerden hangisi doğrudur?
- a) Ham verinin mutlaka normal dağılması gerekir
- b) Varsayım artıkların ya da parametrenin örnekleme dağılımının normalliğiyle ilgilidir
- c) Kolmogorov-Smirnov testi tek başına yeterli kanıttır
- d) Örneklem büyüdükçe normallik daha kritik hâle gelir
- e) Kategorik yordayıcı varsa genel dağılımın normal olması beklenir

- **Doğru:** b · *Varsayım verinin kendisiyle değil, modelin artıkları ya da örnekleme dağılımıyla ilgilidir (Alt başlık 6.4).*
- **8.** Aynı ortalamalar ve standart sapmalarla, yalnızca örneklem büyüklüğü değiştirildiğinde p-değeri ,15'ten ,001'in altına düşmektedir. Bu durumda Cohen d değeri için ne söylenebilir?
- a) d de aynı oranda büyür
- b) d küçülür
- c) d değişmez
- d) d yorumlanamaz hâle gelir
- e) d'nin işareti değişir
- **Doğru:** c · *Etki büyüklüğü örneklem büyüklüğünden bağımsızdır; n yalnızca kestirimin kesinliğini etkiler (Alt başlık 6.5).*
- **9.** ASA'nın p-değeri açıklamasındaki hangi ilke, etki büyüklüğü raporlamanın doğrudan gerekçesidir?
- a) p, modelle bağdaşmazlığı gösterebilir
- b) p, hipotezin doğru olma olasılığını ölçmez
- c) Kararlar tek bir eşiğe dayandırılmamalıdır
- d) p ya da istatistiksel anlamlılık, etkinin büyüklüğünü ya da sonucun önemini ölçmez
- e) Doğru çıkarım şeffaflık gerektirir
- **Doğru:** d · *Beşinci ilke doğrudan etki büyüklüğü ve güven aralığı raporlamayı gerektirir (Alt başlık 6.5).*
- **10.** SPSS'in ANOVA çıktısındaki kısmi eta kare değerini Cohen'in ,01/,06/,14 eşiklerine göre yorumlamanın sorunu nedir?
- a) Kısmi eta kare 1'i aşabilir
- b) Cohen'in eşikleri eta kare için tanımlanmıştır; kısmi eta kare çok faktörlü desenlerde sistematik olarak daha büyüktür
- c) Kısmi eta kare yalnızca t-testinde kullanılır
- d) Kısmi eta kare negatif olabilir
- e) SPSS kısmi eta kareyi hesaplamaz
- **Doğru:** b · *Paydaları farklıdır; eşikleri doğrudan uygulamak etkiyi abartır (Alt başlık 6.5).*
- **11. D/Y:** İstatistiksel olarak anlamlı çıkmayan bir sonuç, gruplar arasında fark bulunmadığı biçiminde raporlanmalıdır.
- **Doğru:** Yanlış · *Anlamsız sonuç yalnızca etkinin bu örneklem büyüklüğüyle bulunabilecek kadar büyük olmadığını söyler; etkinin sıfır olduğunu söylemez (Alt başlık 6.3).*
- **12. Boşluk:** Testin, evrende gerçekten var olan bir etkiyi bulabilme olasılığına ____ denir ve genellikle ,80 hedeflenir.
- **Doğru:** istatistiksel güç | güç | 1 − β · *Güç 1 − β'dır; Cohen'in önerdiği β = ,20 değeri hedef gücü ,80 yapar (Alt başlık 6.3).*

Tartışma İçin

1. Vinyetteki Selin “p zaten anlamlı çıktı” diyor. Bu cümlenin arkasındaki düşünme biçimi nedir ve nasıl düzeltilir?
2. Aynı veride yalnızca örneklem büyüklüğü değiştirilerek p-değerinin taban tabana zıt sonuç vermesi, istatistiksel anlamlılığın hangi sınırını gösterir?
3. ASA'nın üçüncü ilkesi kararların tek bir eşiğe dayandırılmamasını istiyor. Peki eşik olmadan karar nasıl verilecek? Sizin alanınızda alternatif bir ölçüt ne olabilir?
4. Türkçe tezlerde etki büyüklüğünün sıkça raporlanmamasının nedenleri neler olabilir? Bu bir bilgi eksikliği mi, bir gelenek meselesi mi?

5. Fraenkel ve Wallen, istatistiksel anlamlılık testlerinin yalnızca genellenebilirliği değerlendirmek için kullanılmasını öneriyor. Seçkisiz örneklem kullanmayan bir yüksek lisans tezi için bu öneri ne anlama gelir?
6. Bir öğretmen olarak, 40 puanlık bir testte 3,4 puanlık bir farkı sınıfınızda uygulamayı değiştirmek için yeterli sayar mıydınız? Kararınızı hangi ek bilgiye göre verirdiniz?
7. Aykırı değeri silmek ile analizi hem onunla hem onsuz raporlamak arasındaki fark, araştırma etiği açısından nasıl değerlendirilmelidir?

Araştırma Alıştırması 6

Dördüncü haftada yazdığınız hipotez ve değişkenleri, beşinci haftada seçtiğiniz ölçme araçlarını önünüze koyun. **Uygulama Yaprağı 6**, bu iki yaprağı bir analiz planına çevirir. Her araştırma sorunuz için sırayla şunu yazın: bağımlı ve bağımsız değişken, her birinin ölçek düzeyi, grup sayısı ve grupların bağımsız mı ilişkili mi olduğu, seçtiğiniz test ve seçim gerekçesi. Ardından o testin varsayımlarını listeleyin ve her birini nasıl denetleyeceğinizi yazın. Son olarak hangi etki büyüklüğünü raporlayacağınıza karar verin ve **sahte bir çıktı üzerinden** APA 7 biçiminde bir bulgu cümlesi yazın. Veriyi henüz toplamadınız; amaç, toplayınca ne yapacağınızı şimdiden bilmektir.

Uygulama Yaprağı 6 — Nicel Analiz Planı

> UYGULAMA **Nasıl doldurulur.** Bu yaprak, UY4'teki hipotez ve değişkenlerle UY5'teki ölçme araçlarını bir **analiz planına** çevirir. Doğru testi ilk denemede bulmanız beklenmiyor; **bir seçim yapıp gerekçelendirmeniz** bekleniyor. Yaprağı doldurduğunuzda elinizde, veri toplanmadan önce yazılmış bir analiz protokolü olacak — ASA'nın dördüncü ilkesinin (şeffaflık) somut karşılığı budur.

Ad soyad: _____ **Program:** _____ **Tarih:** _____

1 · UY4'ten aktarım: hipotez ve değişkenler

Dördüncü haftada yazdığınız hipotezi ve değişkenleri buraya aktarın.

Alan	UY4'te yazdığım
Araştırma sorusu 1	
Araştırma sorusu 2	
Hipotez (varsa)	
Bağımsız değişken(ler)	
Bağımlı değişken(ler)	
Kontrol / karıştırıcı değişkenler	
Planlanan örneklem büyüklüğü ve seçim yöntemi	

2 · UY5'ten aktarım: ölçme araçları ve ölçek düzeyleri

Değişken	Ölçme aracı	Ölçek düzeyi	Puan aralığı
		☐ sınıflama ☐ sıralama ☐ eşit aralıklı ☐ oran	
		☐ sınıflama ☐ sıralama ☐ eşit aralıklı ☐ oran	

Değişken	Ölçme aracı	Ölçek düzeyi	Puan aralığı
		☐ sınıflama ☐ sıralama ☐ eşit aralıklı ☐ oran	
		☐ sınıflama ☐ sıralama ☐ eşit aralıklı ☐ oran	

ÖRNEK **Doldurulmuş örnek satır.** *Değişken:* Tarihsel düşünme becerisi · *Ölçme aracı:* Araştırmacı tarafından geliştirilen 40 maddelik başarı testi (KR-20 = ,84) · *Ölçek düzeyi:* eşit aralıklı · *Puan aralığı:* 0–40. — İkinci satır: *Değişken:* Grup · *Ölçme aracı:* Uygulama kaydı · *Ölçek düzeyi:* sınıflama (1 = deney, 2 = kontrol) · *Puan aralığı:* 1–2.

3 · Her araştırma sorusu için test seçimi

Şekil 6.2'deki akış şemasını kullanarak doldurun. Her satır bir araştırma sorusudur.

Soru no	Bağımlı değişken (düzey)	Bağımsız değişken (grup sayısı)	Bağımsız / ilişkili	Seçtiğim test
1				
2				
3				

ÖRNEK **Doldurulmuş örnek satır.** *Soru no:* 1 · *Bağımlı değişken:* Tarihsel düşünme puanı (eşit aralıklı, 0–40) · *Bağımsız değişken:* Grup (2 grup: deney/kontrol) · *Bağımsız/ilişkili:* bağımsız · *Seçtiğim test:* Bağımsız örneklemler t-testi. **Gerekçe:** Bağımlı değişken sürekli, iki ayrı öğrenci grubu karşılaştırılıyor ve aynı öğrenciler iki kez ölçülmüyor.

Seçimlerimin gerekçesi (her soru için birer cümle):

1) _____

2) _____

3) _____

4 · Varsayım denetim listesi

Seçtiğiniz her test için ilgili satırları işaretleyin ve nasıl denetleyeceğinizi yazın.

Varsayım	Nasıl denetleyeceğim	Karşılanmazsa ne yapacağım
Aykırı değer denetimi (histogram + kutu grafiği)		
Normallik (histogram, Q-Q, çarpıklık-basıklık)		
Varyans homojenliği (Levene + varyans oranı)		
Bağımsızlık (desen mantığı)		
Ki-kare: beklenen frekans ≥ 5		
Regresyon: çoklu bağlantı (VIF, tolerans)		

5 · Raporlanacak etki büyüklüğü

- ☐ Cohen d (iki ortalama karşılaştırması)
- ☐ Eta kare η^2 (tek yönlü ANOVA)
- ☐ Kısmi eta kare η^2_p (çok faktörlü desen — hangisini yazdığınızı belirtin)
- ☐ Pearson r (korelasyon; katsayının kendisi etki büyüklüğüdür)
- ☐ R^2 / düzeltilmiş R^2 (regresyon)
- ☐ Cramér V (ki-kare)
- ☐ Odds oranı (2×2 çapraz tablo)

Hangi eşiklere göre yorumlayacağım ve neden: _____

_____

6 · Örnek APA 7 cümlesi taslağı

TANIM **Cümle kalıbı.** "_____ grubunun _____ ortalaması (M = ____; SS = ____; n = ____), _____ grubundan (M = ____; SS = ____; n = ____) _____ bulunmuştur, t(__) = ____; p = ____; d = ____; %95 GA [____ – ____]. Bu, Cohen'in ölçütlerine göre _____ düzeyde bir etkidir."

Kendi taslağım:

_____

_____

_____

7 · Sahte çıktı üzerinden yorum yazma

ÖRNEK **Sahte (hayali) SPSS çıktısı — bunu yorumlayın.** Varsayalım ki bir tarama çalışmasında öğretmen adaylarının teknoloji öz-yeterlik puanları cinsiyete göre karşılaştırıldı. **Kadın:** n = 214, M = 3,62; SS = 0,58. **Erkek:** n = 186, M = 3,71; SS = 0,61. **Levene:** F = 0,84; p = ,360. **t-testi:** t(398) = 1,51; p = ,132. **Cohen d = 0,15.** — Bu çıktıyı iki cümleyle yorumlayın: birinci cümle bulguyu, ikinci cümle sınırı söylesin.

Yorumum (1. cümle — bulgu): _____

_____

Yorumum (2. cümle — sınır ve büyüklük): _____

_____

BİLGİ **Beklenen yorumun anahtarı.** Birinci cümle: fark istatistiksel olarak anlamlı **değildir** (t(398) = 1,51; p = ,132). İkinci cümle: bu, "fark yoktur" demek değildir; d = 0,15 Cohen'in ölçütlerine göre küçük bir etkidir ve 400 kişilik bir örneklemle bile bulunacak kadar büyük olmamıştır. "Kadın ve erkek öğretmen adayları arasında fark yoktur" cümlesini **yazmayın.**

8 · Şeffaflık beyanı

Soru	Cevabım
Kaç hipotez sınayacağım?	

Soru	Cevabım
Çoklu karşılaştırma düzeltmesi yapacak mıyım? Hangisi?	
Örneklem büyüklüğüne nasıl karar verdim (güç analizi yaptım mı)?	
Aykırı değer kuralımı veri toplamadan önce yazdım mı?	
Analiz sözdizimimi (syntax) saklayacak mıyım?	

Kendini denetle

- ☐ Her araştırma sorum için tek bir test seçtim ve gerekçesini yazdım.
- ☐ Her değişkenimin ölçek düzeyini işaretledim ve seçtiğim testle uyumlu olduğunu denetledim.
- ☐ Varsayım denetim listesini doldurdum; karşılanmama durumunda ne yapacağımı yazdım.
- ☐ Hangi etki büyüklüğünü raporlayacağıma karar verdim ve (kullanacaksam) eta kare mi kısmi eta kare mi olduğunu belirttim.
- ☐ En az bir APA 7 bulgu cümlesi taslağı yazdım; içinde tam p-değeri ve etki büyüklüğü var.
- ☐ Sahte çıktıyı yorumlarken “fark yoktur” cümlesini kurmadım.

Sosyal Bilgiler Penceresi

Sosyal bilgiler eğitiminde nicel analiz, alanın kendi kavramlarıyla sürekli bir gerilim içindedir. Bu alanın hedefleri — tarihsel düşünme, mekânsal algı, etkin yurttaşlık, değer kazanımı, kültürel miras bilinci — doğrudan sayılabilir şeyler değildir. Her biri önce bir ölçme aracına dönüştürülmüş, sonra puanlanmış, sonra analiz edilmiştir. Yani elinizdeki 27,5'lik ortalama, “tarihsel düşünme”nin kendisi değil, sizin ya da bir başkasının onu ölçmek için kurduğu aracın verdiği sayıdır. Beşinci haftada geçerlik tartışmasını bu yüzden yaptık; altıncı haftanın bütün sayıları o tartışmanın üzerine oturur.

Bu gerilimin pratik bir sonucu vardır. Türkiye'de sosyal bilgiler eğitimi alanındaki lisansüstü tezlerin büyük bölümü, geliştirilmiş ya da uyarlanmış bir ölçekle toplanan verinin t-testi ve ANOVA'yla karşılaştırılmasına dayanır. Bu kötü bir şey değildir; ama bir riski vardır: ölçeğin ölçtüğü şey ile araştırma sorusunun sorduğu şey arasındaki mesafe, analiz aşamasında görünmez hâle gelir. Bir “tarihsel empati ölçeği” gerçekten empatiyi mi ölçüyor, yoksa öğrencinin ders kitabı diline aşinalığını mı? Analiz bu soruyu sormaz; analiz kendisine verilen sayıyı işler. Soruyu sormak size düşer ve yeri tartışma bölümüdür.

İkinci bir alan gerçeği, örneklemle ilgilidir. Sosyal bilgiler eğitiminde yürütülen çalışmaların çoğu, tek bir ildeki birkaç okuldan toplanan uygun örneklemle yapılır; seçkisiz örnekleme çok seyrektir. Fraenkel ve Wallen'ın uyarısı burada doğrudan sizi ilgilendirir: karşılaştırılan gruplar belirli evrenlerden seçkisiz örneklem değilse, olasılıklar ve anlamlılık düzeyleri bilinmeyen bir dereceye kadar hatalıdır ve kaba göstergeler olarak yorumlanmalıdır (2009, s. 245). Bunun size söylediği şey, çıkarımsal istatistiği bırakmanız değil; bulgularınızı “Türkiye'de öğrenciler…” diye başlayan cümlelerle genellememenizdir. Beş sabit sorunun üçüncüsü — temsil — tam burada devreye girer.

Üçüncüsü, alanın kendi karşılaştırma birikiminin zayıf olmasıdır. Cohen'in ,20/,50/,80 eşikleri son çare uzlaşımlarıdır; asıl doğru olan, bulduğunuz etkiyi alanın kendi dağılımıyla karşılaştırmaktır. Sosyal bilgiler eğitiminde bu karşılaştırmayı yapmak için gerekli meta-analitik birikim henüz sınırlıdır. Yapabileceğiniz şey basit ve değerlidir: tartışma bölümünde kendi etki büyüklüğünüzü, aynı kavramı çalışan üç dört Türkçe çalışmanın etki büyüklükleriyle yan yana koyun. Bu, hem sizin yorumunuzu güçlendirir hem de alana bir tuğla ekler. Çalışmalar etki büyüklüğü raporlamamışsa, bu boşluğun kendisi tartışılmaya değer bir bulgudur.

Son olarak, bu haftanın alan sorusu şudur: sosyal bilgiler öğretmeni olarak sizin en güçlü yanınız, bir sayının sınıfta ne anlama geldiğini bilmenizdir. 40 puanlık bir testte 3,4 puanlık fark, bir istatistikçi için yalnızca bir sayıdır; sizin içinse yaklaşık üç maddelik bir farktır ve o üç maddenin hangi kazanımı yokladığını biliyorsunuzdur. Bu bilgiyi tartışma bölümüne taşıyın. **İyi bir nicel tez, sayıyı hesaplayan tez değil, sayının pratikte neye karşılık geldiğini söyleyebilen tezdir.** Uygulama Yaprağı 6'nın son iki maddesi — APA cümlesi ve sahte çıktı yorumu — tam olarak bu beceriyi çalıştırır.

Kaynakça

- American Psychological Association. (2020). *Publication manual of the American Psychological Association* (7. bs.). https://doi.org/10.1037/0000165-000
- Appelbaum, M., Cooper, H., Kline, R. B., Mayo-Wilson, E., Nezu, A. M. ve Rao, S. M. (2018). Journal article reporting standards for quantitative research in psychology: The APA Publications and Communications Board task force report. *American Psychologist*, *73*(1), 3–25. https://doi.org/10.1037/amp0000191
- Balcı, A. (2025). *Sosyal bilimlerde araştırma: Yöntem, teknik ve ilkeler* (17. bs.). Pegem Akademi.
- Baur, N. ve Hergesell, J. (2021). Time series: A statistical method for longitudinal analysis. J.-F. Morin, C. Olsson ve E. Ö. Atikcan (Ed.), *Research methods in the social sciences: An A–Z of key concepts* içinde (s. 288–291). Oxford University Press.
- Büyüköztürk, Ş. (2025). *Sosyal bilimler için veri analizi el kitabı: İstatistik, araştırma deseni SPSS uygulamaları ve yorum* (32. bs.). Pegem Akademi.
- Büyüköztürk, Ş., Kılıç Çakmak, E., Akgün, Ö. E., Karadeniz, Ş. ve Demirel, F. (2025). *Eğitimde bilimsel araştırma yöntemleri* (37. bs.). Pegem Akademi.
- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2. bs.). Lawrence Erlbaum Associates. https://doi.org/10.4324/9780203771587
- Cohen, J. (1992). A power primer. *Psychological Bulletin*, *112*(1), 155–159. https://doi.org/10.1037/0033-2909.112.1.155
- Cohen, J. (1994). The earth is round (p < .05). *American Psychologist*, *49*(12), 997–1003. https://doi.org/10.1037/0003-066X.49.12.997
- Field, A. (2018). *Discovering statistics using IBM SPSS statistics* (5. bs.). SAGE.
- Fraenkel, J. R. ve Wallen, N. E. (2009). *How to design and evaluate research in education* (7. bs.). McGraw-Hill.
- Karasar, N. (t.y.). *Bilimsel araştırma yöntemi: Kavramlar, ilkeler, teknikler*. Nobel Akademik Yayıncılık.
- Laurens, N. (2021). Meta-analysis. J.-F. Morin, C. Olsson ve E. Ö. Atikcan (Ed.), *Research methods in the social sciences: An A–Z of key concepts* içinde (s. 163–165). Oxford University Press.
- Liebe, U. (2021). Factor analysis: Uncovering unobservable constructs. J.-F. Morin, C. Olsson ve E. Ö. Atikcan (Ed.), *Research methods in the social sciences: An A–Z of key concepts* içinde (s. 115–119). Oxford University Press.
- Marcinkiewicz, K. ve Schnapp, K.-U. (2021). Regression analysis. J.-F. Morin, C. Olsson ve E. Ö. Atikcan (Ed.), *Research methods in the social sciences: An A–Z of key concepts* içinde (s. 233–238). Oxford University Press.
- Morin, J.-F., Olsson, C. ve Atikcan, E. Ö. (Ed.). (2021). *Research methods in the social sciences: An A–Z of key concepts*. Oxford University Press.
- Schmidt, S. (2021). Replication and reproducibility. J.-F. Morin, C. Olsson ve E. Ö. Atikcan (Ed.), *Research methods in the social sciences: An A–Z of key concepts* içinde (s. 238–242). Oxford University Press.

- Singh, K. (2026). *Social research methods and applications: Qualitative, quantitative, and mixed methods approaches*. Routledge. https://doi.org/10.4324/9781003593225
- Stockemer, D. (2019). *Quantitative methods for the social sciences: A practical introduction with examples in SPSS and Stata*. Springer. https://doi.org/10.1007/978-3-319-99118-4
- Tkacheva, O. (2021). Statistical significance. J.-F. Morin, C. Olsson ve E. Ö. Atikcan (Ed.), *Research methods in the social sciences: An A–Z of key concepts* içinde (s. 269–272). Oxford University Press.
- Van Ingelgom, V. ve Versailles, A. (2021). Covariance: A first step in the analysis of the relationship between two variables. J.-F. Morin, C. Olsson ve E. Ö. Atikcan (Ed.), *Research methods in the social sciences: An A–Z of key concepts* içinde (s. 67–68). Oxford University Press.
- Wasserstein, R. L. ve Lazar, N. A. (2016). The ASA statement on p-values: Context, process, and purpose. *The American Statistician*, *70*(2), 129–133. https://doi.org/10.1080/00031305.2016.1154108
- Wilkinson, L. ve APA Task Force on Statistical Inference. (1999). Statistical methods in psychology journals: Guidelines and explanations. *American Psychologist*, *54*(8), 594–604.
- Williams, M., Wiggins, R. D. ve Vogt, W. P. (2021). *Beginning quantitative research*. SAGE.
- Yükseköğretim Kurulu. (t.y.). *Ulusal Tez Merkezi*. https://tez.yok.gov.tr